

**PENERAPAN *MULTILINGUAL BERT* UNTUK KLASIFIKASI
BAHASA INDONESIA DAN ATAU BAHASA MALAYSIA
PADA TEKS PENDEK MEDIA SOSIAL**

LAPORAN TUGAS AKHIR

Laporan ini disusun untuk memenuhi salah satu syarat memperoleh
Gelar Sarjana Strata 1 (S1) pada Program Studi Teknik Informatika
Fakultas Teknologi Industri Universitas Islam Sultan Agung Semarang



DISUSUN OLEH:

MOCH. CHAIDAR CHANIF


32602100066

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
UNIVERSITAS ISLAM SULTAN AGUNG
SEMARANG
2025**

***IMPLEMENTATION OF MULTILINGUAL BERT FOR
CLASSIFICATION OF INDONESIAN AND/OR MALAYSIAN
LANGUAGES IN SHORT TEXTS ON SOCIAL MEDIA***

FINAL PROJECT

*Proposed to complete the requirement to obtain a bachelor's degree (S1) at
Informatics Engineering Departement of Industrial Technology Faculty Sultan
Agung Islamic University*



ARRANGED BY:

MOCH. CHAIDAR CHANIF

32602100066

***MAJORING OF INFORMATICS ENGINEERING
INDUSTRIAL TECHNOLOGY FACULTY
SULTAN AGUNG ISLAMIC UNIVERSITY
SEMARANG***

2025

**LEMBAR PENGESAHAN
TUGAS AKHIR**

**PENERAPAN *MULTILINGUAL BERT* UNTUK KLASIFIKASI BAHASA
INDONESIA DAN ATAU BAHASA MALAYSIA PADA TEKS PENDEK
MEDIA SOSIAL**

**MOCH. CHAIDAR CHANIF
NIM 32602100066**


Telah dipertahankan di depan tim penguji ujian sarjana tugas akhir
Program Studi Teknik Informatika
Universitas Islam Sultan Agung
Pada tanggal : 25 Agustus 2025

TIM PENGUJI UJIAN SARJANA :

Andi Riansvah, ST, M.Kom.

NIK. 210616053

(Penguji 1)




28 - 08 - 2025

Asih Widi Harini, S.Si, MT

NIK. 110010398

(Penguji 2)




28 - 08 - 2025

Imam Much Ibnu Subroto

S.T., M.Sc., Ph.D

NIK. 210600017

(Pembimbing)



01 - 09 - 2025


Semarang, 02 September 2025

Mengetahui,

Kaprodi Teknik Informatika
Universitas Islam Sultan Agung

Moch. Taufik., ST, MIT

NIK. 210604034



SURAT PERNYATAAN KEASLIAN TUGAS AKHIR

Yang bertanda tangan dibawah ini :

Nama : Moch. Chaidar Chanif

NIM : 32602100066

Judul Tugas Akhir : PENERAPAN *MULTILINGUAL BERT* UNTUK
KLASIFIKASI BAHASA INDONESIA DAN ATAU
BAHASA MALAYSIA PADA TEKS PENDEK MEDIA
SOSIAL

Dengan bahwa ini saya menyatakan bahwa judul dan isi Tugas Akhir yang saya buat dalam rangka menyelesaikan Pendidikan Strata Satu (S1) Teknik Informatika tersebut adalah asli dan belum pernah diangkat, ditulis ataupun dipublikasikan oleh siapapun baik keseluruhan maupun sebagian, kecuali yang secara tertulis diacu dalam naskah ini dan disebutkan dalam daftar pustaka, dan apabila di kemudian hari ternyata terbukti bahwa judul Tugas Akhir tersebut pernah diangkat, ditulis ataupun dipublikasikan, maka saya bersedia dikenakan sanksi akademis. Demikian surat pernyataan ini saya buat dengan sadar dan penuh tanggung jawab.

Semarang, 25 Agustus 2025



Moch. Chaidar Chanif

PERNYATAAN PERSETUJUAN PUBLIKASI KARYA ILMIAH

Saya yang bertanda tangan dibawah ini :

Nama : Moch. Chaidar Chanif

NIM : 32602100066

Program Studi : Teknik Informatika

Fakultas : Teknologi industri

Alamat Asal : Semarang

Dengan ini menyatakan Karya Ilmiah berupa Tugas akhir dengan Judul : Penerapan *Multilingual BERT* untuk Klasifikasi Bahasa Indonesia dan atau Bahasa Malaysia pada Teks Pendek Media Sosial.

Menyetujui menjadi hak milik Universitas Islam Sultan Agung serta memberikan Hak bebas Royalti Non-Eksklusif untuk disimpan, dialihmediakan, dikelola dan pangkalan data dan dipublikasikan di internet dan media lain untuk kepentingan akademis selama tetap menyantumkan nama penulis sebagai pemilik hak cipta. Pernyataan ini saya buat dengan sungguh-sungguh. Apabila di kemudian hari terbukti ada pelanggaran Hak Cipta/Plagiarisme dalam karya ilmiah ini, maka segala bentuk tuntutan hukum yang timbul akan saya tanggung secara pribadi tanpa melibatkan Universitas Islam Sultan agung.

Semarang, 25 Agustus 2025



Moch. Chaidar Chanif

KATA PENGANTAR

Puji syukur penulis panjatkan kepada ALLAH SWT, yang telah memberikan rahmat, taufik serta hidayah-Nya, sehingga penulis dapat menyelesaikan Tugas Akhir yang berjudul “Penerapan Multilingual BERT untuk Klasifikasi Bahasa Indonesia dan atau Bahasa Malaysia pada Teks Pendek Media Sosial.” ini dengan baik. Dengan penuh rasa hormat, penulis menyampaikan ucapan terima kasih yang sebesar-besarnya kepada:

1. Rektor UNISSULA Bapak Prof. Dr. H. Gunarto, SH., M.Hum yang mengizinkan penulis menimba ilmu di kampus ini.
2. Dekan Fakultas Teknologi Industri Ibu Dr. Ir. Hj. Novi Marlyana, S.T., M.T
3. Dosen pembimbing penulis Bapak Imam Much Ibnu Subroto, ST., M.Sc., Ph.D yang telah memberikan arahan, bimbingan, dan saran yang berarti dalam penyelesaian tugas akhir ini.
4. Seluruh dosen Program Studi Teknik Informatika, Fakultas Teknologi Industri UNISSULA yang telah memberikan ilmunya kepada penulis.
5. Orang tua penulis, Bapak Lukman Hakim dan Ibu Rodhiyah serta kedua adik penulis yaitu Arjun dan Arfi, yang selalu memberikan segala doa, dukungan, dan motivasi dengan penuh kasih sayang sehingga penulis dapat menyelesaikan tugas akhir ini dengan baik.
6. Teman-teman seperjuangan khususnya anak-anak satu kontrakan, atas kebersamaanya yang telah bekerja keras serta semangat dalam proses penyelesaian tugas akhir ini.

Semarang, 25 Agustus 2025


Penulis

Moch. Chaidar Chanif

DAFTAR ISI


HALAMAN JUDUL	i
LEMBAR PENGESAHAN TUGAS AKHIR	ii
SURAT PERNYATAAN KEASLIAN TUGAS AKHIR	iii
PERNYATAAN PERSETUJUAN PUBLIKASI KARYA ILMIAH	iv
KATA PENGANTAR	v
DAFTAR ISI	vi
DAFTAR GAMBAR	viii
DAFTAR TABEL	ix
ABSTRAK	x
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Perumusan Masalah	3
1.3 Batasan Masalah	3
1.4 Tujuan Penelitian	3
1.5 Manfaat Penelitian	3
1.6 Sistematika Penulisan	4
BAB II TINJAUAN PUSTAKA DAN DASAR TEORI	5
2.1 Tinjauan Pustaka	5
2.2 Dasar Teori	6
2.2.1 Sistem Klasifikasi	6
2.2.2 Multilingual BERT (mBert)	8
2.2.3 Bahasa Indonesia	11
2.2.4 Bahasa Malaysia	12
2.2.5 Teks Pendek	13
2.2.6 Media Sosial	14
2.2.7 Evaluasi Model	15
BAB III METODE PENELITIAN	14
3.1 Metode Penelitian	14
3.1.1 Studi Literatur	15
3.1.2 Pengumpulan Data	15
3.1.3 Perancangan Sistem	16
3.1.4 <i>Preprocessing Data</i>	19
3.1.5 Pelatihan Model	20
3.1.6 Evaluasi Model	21

3.1.7	<i>Deployment Model</i>	22
3.2	Analisis Sistem.....	23
3.3	Identifikasi Perangkat Lunak.....	25
3.4	Perancangan <i>User Interface</i>	30
BAB IV HASIL DAN ANALISIS PENELITIAN		34
4.1	Hasil Penelitian	34
4.1.1	Hasil Pengumpulan data.....	35
4.1.2	Hasil <i>Preprocessing Data</i>	37
4.1.3	Implementasi Pelatihan Model.....	39
4.1.4	Evaluasi Model.....	40
4.2	Hasil Implementasi	45
4.2.1	Halaman Awal Sistem Klasifikasi	45
4.2.2	Halaman Hasil Sistem Klasifikasi	46
4.2.3	Ringkasan Pengujian Implementasi.....	48
BAB V KESIMPULAN		49
5.1	Kesimpulan.....	49
5.2	Saran.....	49
DAFTAR PUSTAKA.....		51
LAMPIRAN.....		53



DAFTAR GAMBAR

Gambar 2. 1 Arsitektur Model Bert	9
Gambar 3. 1 Alur Penelitian.....	14
Gambar 3. 2 Pengumpulan Data	15
Gambar 3. 3 Flowchart Perancangan Sistem	17
Gambar 3. 4 Flowchart Preprocessing	19
Gambar 3. 5 Flowchart Perancangan Sistem	24
Gambar 3. 6 Halaman Utama.....	30
Gambar 3. 7 Halaman Klasifikasi	31
Gambar 4. 1 Dataet yang telah di kumpulkan.....	35
Gambar 4. 2 Confusion Matrix Label Bahasa Indonesia	42
Gambar 4. 3 Confusion Matrix Label Bahasa Malaysia	43
Gambar 4. 4 Halaman Utama.....	46
Gambar 4. 5 Halaman Hasil Klasifikasi.....	47



DAFTAR TABEL

Tabel 4. 1 Distribusi <i>Dataset</i> Bahasa Indonesia dan Bahasa Malaysia	36
Tabel 4. 2 <i>Classification Report</i>	44
Tabel 4. 3 Hasil Klasifikasi Contoh Teks Uji	49



ABSTRAK

Bahasa Indonesia dan Bahasa Malaysia memiliki akar linguistik yang sama sehingga sering menunjukkan kemiripan kosakata dan struktur kalimat, namun juga menyimpan perbedaan makna yang dapat menimbulkan ambiguitas, khususnya pada teks pendek di media sosial. Kondisi ini menjadi tantangan dalam pengklasifikasian bahasa secara otomatis. Penelitian ini bertujuan mengimplementasikan model *Multilingual Bidirectional Encoder Representations from Transformers (mBERT)* untuk membedakan Bahasa Indonesia dan Bahasa Malaysia pada teks pendek dari platform Twitter. Data dikumpulkan melalui web scraping dengan panjang teks 1–20 kata, menghasilkan total 56.701 data, dengan distribusi Bahasa Indonesia (48,47%), Bahasa Malaysia (14,31%), dan campuran keduanya (37,22%). Proses penelitian mencakup *preprocessing* (pembersihan teks, *case folding*, normalisasi, tokenisasi), pembagian data latih dan uji (80:20), *fine-tuning* mBERT, serta evaluasi menggunakan akurasi, precision, recall, dan F1-score. Hasil pengujian menunjukkan bahwa model mBERT mencapai akurasi 95,8%, precision 97,9%, recall 95,1%, dan F1-score 96,5%, dengan performa stabil pada kedua kelas bahasa. Kesimpulan penelitian ini adalah mBERT efektif dan andal dalam mengklasifikasikan bahasa yang memiliki kemiripan tinggi pada teks pendek media sosial, sehingga berpotensi diterapkan pada pengolahan bahasa alami untuk bahasa-bahasa serumpun lainnya.

Kata Kunci: Klasifikasi Bahasa, Bahasa Indonesia, Bahasa Malaysia, mBERT, Teks Pendek, Media Sosial, NLP.

ABSTRACT

Indonesian and Malay share the same linguistic roots, which often results in similarities in vocabulary and sentence structure, yet they also contain semantic differences that may cause ambiguity, particularly in short texts on social media. This condition poses a challenge for automatic language classification. This study aims to implement the Multilingual Bidirectional Encoder Representations from Transformers (mBERT) model to distinguish between Indonesian and Malay in short texts collected from Twitter. The dataset was obtained through web scraping with text lengths ranging from 1 to 20 words, resulting in a total of 56,701 entries, consisting of Indonesian (48.47%), Malay (14.31%), and mixed-language texts (37.22%). The research process involved preprocessing (text cleaning, case folding, normalization, tokenization), splitting the dataset into training and testing sets (80:20), fine-tuning mBERT, and evaluating the model using accuracy, precision, recall, and F1-score. The experimental results demonstrate that the mBERT model achieved 95.8% accuracy, 97.9% precision, 95.1% recall, and 96.5% F1-score, showing stable performance across both language classes. This study concludes that mBERT is effective and reliable in classifying highly similar languages in short social media texts and has potential applications in natural language processing tasks for other closely related languages.

Keywords: Language Classification, Indonesian, Malaysian, mBERT, Short Text, Social Media, NLP.

BAB I

PENDAHULUAN

1.1 Latar Belakang

Bahasa Indonesia dan Bahasa Malaysia merupakan dua bahasa serumpun yang memiliki akar linguistik yang sama, sehingga sering menunjukkan kemiripan dalam kosakata, tata bahasa, maupun struktur kalimat. Namun, di balik kemiripan tersebut terdapat sejumlah perbedaan makna yang berpotensi menimbulkan ambiguitas. Misalnya, kata *bisa* dalam Bahasa Indonesia berarti “mampu”, sedangkan dalam Bahasa Malaysia berarti “racun”. Kata *tewas* di Indonesia bermakna “meninggal dunia”, tetapi di Malaysia justru dipahami sebagai “kalah dalam pertandingan”. Demikian pula, *seronok* di Malaysia berarti “menyenangkan”, namun di Indonesia cenderung dimaknai negatif. Perbedaan makna seperti ini seringkali menimbulkan salah tafsir ketika digunakan dalam komunikasi lintas negara (Kajian dkk., 2012)

Fenomena salah paham ini semakin terlihat di media sosial, khususnya Twitter, yang menjadi ruang interaksi publik bagi masyarakat Indonesia dan Malaysia. Karakteristik teks pendek di platform tersebut singkat, tidak baku, dan sering menggunakan singkatan membuat konteks percakapan menjadi terbatas. Kondisi ini memperbesar kemungkinan terjadinya kesalahpahaman antar pengguna dari kedua negara. Beberapa kali, perbedaan pemaknaan kata bahkan memicu perdebatan di ruang digital, memperlihatkan pentingnya sistem yang mampu membedakan Bahasa Indonesia dan Bahasa Malaysia secara akurat.

Urgensi masalah ini semakin jelas jika melihat besarnya interaksi pengguna kedua negara di media sosial. Pada tahun 2024, Indonesia menempati peringkat keempat dunia dengan sekitar 27,1 juta pengguna Twitter, sementara Malaysia memiliki sekitar 5,71 juta pengguna atau sekitar 17% dari total penduduknya (World Population Review, 2024). Dominasi pengguna dari kedua negara ini memperbesar risiko kesalahpahaman melalui teks pendek di Twitter, di mana konteks sering hilang dan kesamaan kata bisa memicu konflik digital. Oleh karena itu, dibutuhkan sistem klasifikasi otomatis yang mampu membedakan Bahasa Indonesia dan Bahasa Malaysia dengan lebih akurat.

Masalah ini menjadi semakin menantang karena kedua bahasa masih termasuk kategori *low-resource languages* dalam bidang *Natural Language Processing* (NLP). Model NLP global seperti Google Translate, ChatGPT, atau sistem pencarian cerdas seringkali keliru dalam membedakan teks Bahasa Indonesia dan Bahasa Malaysia, terutama pada konteks informal di media sosial (Maxwell-Smith dkk., 2020). Hal ini menunjukkan perlunya penelitian yang berfokus pada pengembangan model klasifikasi khusus untuk kedua bahasa tersebut.

Beberapa penelitian terdahulu menunjukkan bahwa pendekatan berbasis *transformer* lebih unggul dibandingkan metode tradisional dalam menangani klasifikasi teks pendek. Model *Bidirectional Encoder Representations from Transformers* (BERT), misalnya, mampu memahami konteks kalimat secara mendalam meskipun jumlah kata terbatas (Singh dkk., 2021). Salah satu variannya, yaitu *Multilingual BERT* (mBERT), dirancang untuk mendukung lebih dari 100 bahasa termasuk Bahasa Indonesia dan Bahasa Malaysia. Dengan kemampuannya dalam memahami representasi bahasa lintas negara, mBERT memiliki potensi besar untuk diterapkan dalam membedakan kedua bahasa tersebut pada teks pendek di media sosial. Studi sebelumnya bahkan membuktikan bahwa mBERT efektif dalam mendeteksi teks Melayu di media sosial, termasuk pada skenario *zero-shot* maupun campuran bahasa (Guo dkk., 2024). Di sisi lain, pada salah satu penelitian dijelaskan bahwa penerapan model multibahasa dapat meningkatkan performa klasifikasi teks pendek secara signifikan jika dibandingkan dengan metode tradisional (Putra & Purwarianti, 2020).

Berdasarkan latar belakang tersebut, penelitian ini dilakukan untuk mengembangkan sistem klasifikasi otomatis yang dapat membedakan Bahasa Indonesia dan Bahasa Malaysia pada teks pendek, khususnya dari platform Twitter. Diharapkan hasil penelitian ini dapat memberikan kontribusi dalam bidang NLP untuk bahasa-bahasa serumpun serta membantu mengurangi potensi salah komunikasi yang kerap terjadi di ruang digital.

1.2 Perumusan Masalah

Berdasarkan latar belakang tersebut, penulis mengidentifikasi permasalahan yang akan dibahas yaitu, bagaimana performa model *Multilingual BERT* dalam mengklasifikasikan teks pendek media sosial berbahasa Indonesia dan Malaysia?

1.3 Batasan Masalah

Untuk menjaga fokus dan ruang lingkup penelitian, terdapat beberapa batasan yang ditetapkan yaitu :

1. Data yang digunakan terbatas pada teks pendek yang bersumber dari media sosial yaitu platform Twitter.
2. Batasan kata yang dinyatakan sebagai teks pendek minimal 1 kata dan maksimal 20 kata.
3. Bahasa yang diklasifikasikan hanya terbatas pada Bahasa Indonesia dan Bahasa Malaysia.
4. Model yang digunakan adalah *Multilingual BERT* tanpa melakukan perbandingan performa dengan model klasifikasi lainnya.
5. Penelitian hanya berfokus pada klasifikasi bahasa, tidak mencakup analisis semantik, penerjemahan, atau tugas NLP lainnya.

1.4 Tujuan Penelitian

Tujuan dari penelitian ini adalah untuk mengimplementasikan model *Multilingual BERT* dalam melakukan klasifikasi Bahasa Indonesia dan Bahasa Malaysia pada teks pendek media sosial, sehingga dapat menghasilkan sistem klasifikasi yang akurat dan dapat membedakan kedua bahasa tersebut secara efektif.

1.5 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan kontribusi dalam bidang pengolahan bahasa alami (*Natural Language Processing/NLP*), khususnya pada klasifikasi bahasa yang memiliki kemiripan tinggi seperti Bahasa Indonesia dan Bahasa Malaysia. Implementasi model *Multilingual BERT* dalam penelitian ini diharapkan mampu menjadi solusi dalam membedakan kedua bahasa tersebut

secara otomatis dan akurat, terutama pada teks pendek yang umum ditemukan di media sosial.

1.6 ‘

{Sistematika Penulisan

Struktur penulisan yang akan diterapkan dalam pembuatan laporan tugas akhir adalah sebagai berikut :

BAB I : PENDAHULUAN

Pada BAB I dijelaskan tentang latar belakang, pemilihan judul, rumusan masalah, Batasan masalah, tujuan penelitian, metodologi penelitian dan sistematika penelitian

BAB II : TINJAUAN PUSTAKA DAN DASAR TEORI

Pada BAB II dimuat tentang penelitian terdahulu dan landasan teori sebagai dasar dalam memahami klasifikasi teks pendek menggunakan model *Multilingual BERT* (mBERT), khususnya dalam membedakan Bahasa Indonesia dan Bahasa Malaysia.

BAB III : METODE PENELITIAN

Pada BAB III dijelaskan proses penelitian yang dimulai dari pengumpulan data hingga evaluasi hasil prediksi.

BAB IV : HASIL DAN ANALISIS PENELITIAN

Pada BAB IV berisi tentang pemaparan hasil penelitian yang dimulai dari pembuatan sistem sampai dengan proses deployment.

BAB V : KESIMPULAN DAN SARAN

Pada BAB V berisi rangkuman keseluruhan proses penelitian dari awal sampai akhir.

BAB II

TINJAUAN PUSTAKA DAN DASAR TEORI

2.1 Tinjauan Pustaka

Pada Penelitian mengenai klasifikasi bahasa secara otomatis telah berkembang pesat seiring dengan kemajuan teknologi pemrosesan bahasa alami (*Natural Language Processing*). Salah satu tantangan dalam klasifikasi bahasa adalah membedakan bahasa-bahasa yang memiliki kesamaan struktural dan leksikal, seperti bahasa Indonesia dan bahasa Malaysia. Kedua bahasa ini berasal dari rumpun yang sama, yaitu Melayu-Polinesia, sehingga memiliki kosakata yang sangat mirip. Namun, perbedaan dalam pemilihan kata, struktur kalimat, serta pengaruh lokal dalam penggunaan bahasa dapat menjadi indikator yang berguna dalam proses klasifikasi.

Beberapa penelitian sebelumnya telah dilakukan untuk mengatasi tantangan dalam klasifikasi bahasa yang saling berkerabat. Salah satu penelitian menggunakan pendekatan pembelajaran mesin berbasis karakter n-gram untuk membedakan antara Bahasa Portugis dan Spanyol yang memiliki kemiripan leksikal tinggi. Meskipun pendekatan ini efektif dalam beberapa kasus, hasil penelitian menunjukkan bahwa metode berbasis fitur sederhana memiliki keterbatasan dalam menangkap konteks semantik yang lebih kompleks (Ansari dkk., 2020).

Penelitian lain melakukan kajian komprehensif terhadap berbagai pendekatan deteksi bahasa, dari metode statistik hingga deep learning, dan menekankan bahwa dalam konteks bahasa yang memiliki kemiripan morfologis dan sintaktis, pemodelan berbasis konteks sangat penting. Dalam kasus Bahasa Indonesia dan Malaysia, pendekatan ini memungkinkan sistem untuk mengenali nuansa makna melalui hubungan antar kata dalam satu kalimat (Jauhiainen dkk., 2019).

Salah satu pendekatan yang populer dalam tugas-tugas klasifikasi bahasa adalah model berbasis transformer seperti BERT karena kemampuannya dalam memahami konteks secara mendalam. Penelitian menunjukkan bahwa *Multilingual BERT* (mBERT) mampu melakukan zero-shot cross-lingual transfer, yaitu kemampuan untuk mentransfer pengetahuan antar bahasa tanpa perlu pelatihan

ulang, dengan hasil yang kompetitif dalam klasifikasi multibahasa (Pires dkk., 2019). Sementara itu, Pengembangan lebih lanjut dilakukan melalui model XLM-RoBERTa (XLM-R), yang menunjukkan peningkatan akurasi dalam klasifikasi bahasa, terutama pada dataset dengan kemiripan linguistik yang tinggi. Model ini memperkuat pendekatan berbasis transformer sebagai solusi yang andal dalam klasifikasi lintas bahasa (Wu & Dredze, 2020).

Dalam penelitian lain, mengeksplorasi kemampuan mBERT dalam mengklasifikasikan bahasa pada data sosial media dan menemukan bahwa akurasi model dapat ditingkatkan dengan teknik *fine-tuning* pada data domain-spesifik. Temuan ini memperkuat gagasan bahwa adaptasi model ke konteks lokal, seperti gaya bahasa di media sosial Indonesia dan Malaysia, merupakan faktor penting dalam keberhasilan klasifikasi. (Singh dkk., 2021)

Dengan memperhatikan studi-studi sebelumnya, dapat disimpulkan bahwa pemilihan model dan pendekatan yang mempertimbangkan konteks semantik merupakan kunci dalam menangani tugas klasifikasi bahasa yang memiliki kemiripan struktural tinggi. Oleh karena itu, dalam penelitian ini dipilihlah pendekatan berbasis *Multilingual BERT* yang memiliki kemampuan memahami konteks antarbahasa, dengan harapan mampu membedakan secara efektif antara bahasa Indonesia dan Malaysia dalam teks pendek dari media sosial.

2.2 Dasar Teori

2.2.1 Sistem Klasifikasi

Klasifikasi merupakan salah satu tugas utama dalam bidang pembelajaran mesin (*machine learning*) dan pemrosesan bahasa alami (Natural Language Processing), yang bertujuan untuk mengelompokkan data ke dalam kategori atau label yang telah ditentukan sebelumnya. Dalam konteks NLP, klasifikasi teks (*text classification*) adalah proses mengklasifikasikan dokumen teks, kalimat, atau frasa ke dalam kelas-kelas tertentu berdasarkan kontennya (Li & Li, 2022).

Secara etimologis, istilah "klasifikasi" berasal dari bahasa Latin *classis* yang berarti pengelompokan berdasarkan kesamaan tertentu. Dalam konteks umum, klasifikasi merujuk pada proses sistematis untuk membagi objek, konsep, atau

entitas ke dalam kategori yang seragam berdasarkan ciri khas yang dimilikinya. Dalam bidang perpustakaan, misalnya, klasifikasi dipahami sebagai proses pengelompokan bahan pustaka atas dasar persamaan isi, bentuk, maupun pengarang, dengan tujuan memudahkan pencarian dan pengelolaan informasi. Konsep dasar ini juga relevan dalam konteks pengolahan data teks dari media sosial yang bersifat informal dan dinamis.

Proses klasifikasi teks umumnya melibatkan beberapa tahapan penting, yaitu:

1. Pra-pemrosesan Teks: Tahap ini mencakup pembersihan data dari karakter-karakter tidak perlu, normalisasi, serta penghapusan kata umum (*stop words*) yang tidak bermakna signifikan.
2. Ekstraksi Fitur: Teks kemudian diubah menjadi representasi numerik agar dapat diproses oleh algoritma. Representasi ini dapat berupa *Bag-of-Words* (BoW), TF-IDF, atau word *embeddings*.
3. Pemilihan dan Pelatihan Model: Model seperti *Naïve Bayes*, *Support Vector Machine* (SVM), *Decision Tree*, hingga model berbasis *deep learning* digunakan untuk belajar dari data yang telah direpresentasikan secara numerik.
4. Evaluasi Model: Model diuji kinerjanya menggunakan metrik seperti akurasi, presisi, recall, dan F1-score.

Perkembangan terkini menunjukkan bahwa model pembelajaran mendalam (*deep learning*) seperti CNN, RNN, dan terutama model *transformer* seperti BERT dan mBERT, mampu menangkap pola-pola semantik yang kompleks dalam teks. Keunggulan *transformer* dalam memahami konteks kata secara mendalam menjadikannya sangat efektif dalam tugas klasifikasi, khususnya pada teks yang mengandung ambiguitas atau variasi linguistik yang tinggi (Haque dkk., 2022; Li & Li, 2022).

Dalam konteks identifikasi bahasa antara Bahasa Indonesia dan Bahasa Malaysia pada teks pendek media sosial, klasifikasi menjadi tantangan menarik. Kedua bahasa memiliki kemiripan dalam struktur dan kosakata, namun perbedaan dalam konteks budaya, idiom, serta pengaruh lokal dapat memengaruhi hasil klasifikasi. Oleh karena itu, pendekatan klasifikasi berbasis representasi

kontekstual seperti mBERT sangat penting untuk menangkap nuansa-nuansa semantik yang tidak tertangkap oleh model tradisional (Kolluri dkk., 2020;Conneau dkk., 2020)

2.2.2 Multilingual BERT (mBert)

Multilingual BERT(mBERT) adalah model pembelajaran mendalam berbasis arsitektur *transformer* yang dikembangkan oleh Google. Model ini merupakan varian dari BERT (*Bidirectional Encoder Representations from Transformers*) yang diperkenalkan oleh (Devlin dkk., 2019), dan awalnya dirancang untuk memahami konteks kata dalam satu bahasa dengan cara dua arah (*bidirectional learning*), di mana model mempertimbangkan kata sebelum dan sesudah dalam sebuah kalimat untuk membangun representasi kata yang kontekstual (*contextualized word representations*).


Berbeda dengan BERT Monolingual, mBERT dilatih menggunakan data dari lebih dari 100 bahasa secara simultan, termasuk Bahasa Indonesia dan Bahasa Malaysia. Dengan pelatihan multibahasa tersebut, mBERT mampu menangkap pola-pola umum lintas bahasa, sehingga dapat digunakan untuk berbagai tugas NLP dalam konteks bahasa yang berbeda, bahkan untuk bahasa yang secara struktural dan leksikal saling berdekatan seperti Bahasa Indonesia dan Bahasa Malaysia.

Pendekatan ini sangat bermanfaat dalam pemrosesan teks dari media sosial, yang umumnya mengandung bahasa tidak formal dan campuran kosakata antar bahasa. Meskipun begitu, tantangan tetap ada, terutama dalam membedakan istilah atau ungkapan yang bersifat budaya atau konteks lokal yang khas dari masing-masing bahasa. Sejumlah studi menunjukkan bahwa kinerja mBERT pada tugas klasifikasi atau identifikasi bahasa masih dapat ditingkatkan ketika menangani bahasa serumpun (Conneau dkk., 2019)

Dalam konteks identifikasi otomatis Bahasa Indonesia dan Bahasa Malaysia, (Abdiansah & Rizqie, 2023) menunjukkan bahwa model pembelajaran mesin seperti *Support Vector Machine* (SVM) dapat secara efektif membedakan kedua bahasa meskipun memiliki kemiripan tinggi. Studi tersebut menyoroti bahwa tantangan utama bukan hanya pada kesamaan leksikal, tetapi juga perbedaan

idiomatik dan penggunaan kosakata informal dalam domain media sosial.

Arsitektur umum dari model BERT yang juga diadopsi oleh mBERT dapat digambarkan seperti berikut:



Gambar 2. 1 Arsitektur Model Bert

Pada gambar 2.1 menunjukkan arsitektur dasar dari model BERT (*Bidirectional Encoder Representations from Transformers*). Proses dimulai dari bagian paling bawah, yaitu *input sequence*, yang merupakan satu atau dua kalimat yang disatukan dengan token khusus [SEP]. Input pada BERT dapat berupa satu atau dua kalimat, di mana token khusus [SEP] digunakan sebagai pembatas atau penutup (Devlin dkk., 2019). Setiap token dalam urutan input ini akan dikonversi menjadi representasi vektor melalui tiga jenis *embedding*: *token embeddings*, *segment embeddings*, dan *position embeddings*. *Token embeddings* merepresentasikan kata atau sub-kata, *segment embeddings* membedakan antara dua kalimat dalam satu input (misalnya kalimat A dan B), sedangkan *position*

embeddings menunjukkan posisi urutan token dalam kalimat agar model memahami urutan.

Vektor-vektor *embedding* ini kemudian dimasukkan ke dalam lapisan *encoder Transformer bidireksional*, yang terdiri dari beberapa blok *Transformer* (dalam gambar disingkat "Trm"). Setiap blok memiliki dua komponen utama: *self-attention* dan *feed-forward neural network*. Mekanisme bidireksional di sini berarti model melihat konteks dari kedua arah kiri dan kanan secara bersamaan, berbeda dari model sebelumnya yang hanya memproses secara satu arah. Lapisan-lapisan *Transformer* ini menghasilkan *contextual embeddings* untuk setiap token, yaitu representasi kata yang memperhitungkan konteks sekelilingnya. Akhirnya, *contextual embeddings* ini disalurkan ke lapisan tugas akhir (*target task layer*), yang menyesuaikan model dengan tugas spesifik seperti klasifikasi, pertanyaan-jawaban, atau ekstraksi entitas. Dengan desain seperti ini, BERT mampu menangkap hubungan semantik antar kata dalam satu kalimat maupun antar kalimat, dan telah terbukti efektif untuk berbagai tugas pemrosesan bahasa alami.

Untuk melatih mBERT, digunakan pendekatan *Masked Language Modeling* (MLM), di mana sebagian token dalam kalimat disembunyikan (*masked*) dan model diminta untuk memprediksi token yang hilang tersebut berdasarkan konteks sekitarnya. Proses ini dirumuskan sebagai berikut:

$$\mathcal{L}_{MLM} = - \sum_{i \in M} \log P(x_i | x_{|MASK|}, \theta) \quad (1)$$

Dengan keterangan:

- M adalah himpunan indeks token yang dimasking dalam kalimat input.
- x_i adalah token asli yang disembunyikan.
- $x_{|MASK|}$ adalah input kalimat yang sudah disensor sebagian tokennya.
- θ adalah parameter model.

Fungsi kerugian ini mendorong model untuk belajar memahami struktur dan konteks kalimat, bahkan dalam data multibahasa, yang merupakan esensi dari

mBERT.

Pendekatan ini sangat relevan untuk Bahasa Indonesia dan Bahasa Malaysia yang secara linguistik memiliki kesamaan struktur, namun juga menyimpan perbedaan dalam pilihan kata dan penggunaan sehari-hari. Dengan demikian, mBERT menjadi pilihan yang kuat untuk tugas klasifikasi teks atau identifikasi bahasa antara kedua bahasa tersebut.

2.2.3 Bahasa Indonesia

Bahasa Indonesia merupakan bahasa nasional dan bahasa resmi Negara Kesatuan Republik Indonesia, yang memiliki fungsi vital sebagai alat komunikasi, identitas nasional, dan pemersatu bangsa. Secara linguistik, Bahasa Indonesia termasuk dalam rumpun bahasa Austronesia, khususnya cabang Melayu-Polinesia (Alwi, 2007).

Sebagai sistem simbolik yang digunakan dalam interaksi sosial, Bahasa Indonesia memiliki struktur yang teratur, terdiri dari unsur fonologi, morfologi, sintaksis, semantik, dan pragmatik. Dalam praktiknya, terutama pada media sosial, penggunaan Bahasa Indonesia sering kali mengalami penyimpangan dari kaidah formal, seperti penggunaan slang, singkatan, hingga pencampuran dengan bahasa asing.

Kondisi ini menyebabkan tantangan tersendiri dalam pemrosesan bahasa alami (*Natural Language Processing*), khususnya dalam klasifikasi teks. Teks berbahasa Indonesia yang muncul di media sosial cenderung pendek, informal, dan kontekstual. Oleh karena itu, model klasifikasi yang digunakan harus mampu memahami konteks kata secara mendalam dan fleksibel.

Dalam konteks pengolahan bahasa, penting juga untuk memperhatikan standar penggunaan Bahasa Indonesia yang telah ditetapkan dalam Pedoman Umum Ejaan Bahasa Indonesia (PUEBI) sebagai acuan dalam penulisan dan struktur bahasa yang benar. Pemodelan Bahasa Indonesia dalam sistem klasifikasi otomatis harus memperhitungkan variasi bahasa yang muncul dari pengguna internet di berbagai daerah, latar belakang, dan usia.

Kamus Besar Bahasa Indonesia (KBBI) merupakan rujukan utama dalam pemahaman kosakata serta struktur formal bahasa Indonesia. KBBI tersedia dalam

berbagai edisi cetak maupun daring, dan kini telah mencapai Edisi VI (2023) dengan sekitar 120.000 entri kata, menjadikannya sumber komprehensif dan paling mutakhir untuk standar kosakata dan makna dalam bahasa Indonesia. Keberadaan KBBI juga sangat penting dalam mendukung validitas pengolahan bahasa alami (NLP), khususnya pada tahap *tokenization* dan normalisasi leksikal, sehingga model seperti mBERT dapat membedakan varian tata tulis informal di media sosial dengan acuan bahasa baku yang dikodifikasi dalam KBBI.(Badan Pengembangan dan Pembinaan Bahasa, 2016)

2.2.4 Bahasa Malaysia

Bahasa Malaysia, atau disebut juga Bahasa Melayu Standar di Malaysia, merupakan bahasa resmi Federasi Malaysia. Bahasa ini berasal dari akar bahasa Melayu Klasik, yang juga menjadi dasar pembentukan Bahasa Indonesia. Meskipun berasal dari sumber yang sama, Bahasa Malaysia telah mengalami perkembangan dan pengaruh tersendiri, baik dari segi ejaan, kosakata, maupun struktur kalimat, seiring dengan perkembangan sejarah, politik, dan budaya di Malaysia(Kajian dkk., 2012).

Secara umum, Bahasa Malaysia dan Bahasa Indonesia memiliki tingkat keterpahaman yang tinggi satu sama lain, terutama dalam wacana formal. Namun, perbedaan signifikan dapat ditemukan pada penggunaan istilah, gaya bahasa, dan konteks budaya. Misalnya, beberapa kata dalam Bahasa Malaysia memiliki makna yang berbeda atau tidak digunakan sama sekali dalam Bahasa Indonesia, dan sebaliknya (Sirulhaq & Kurniawan, 2024)

Kamus Dewan, yang diterbitkan oleh Dewan Bahasa dan Pustaka (DBP), merupakan rujukan utama kosakata baku Bahasa Melayu di Malaysia. Edisi terbarunya memuat lebih dari 49.000 entri yang mencakup definisi, ejaan, dan kelas kata, sehingga menjadi sumber otoritatif bagi pembakuan bahasa(Dewan Bahasa dan Pustaka, 2005). Dalam konteks pemrosesan bahasa alami, Kamus Dewan memiliki peran penting dalam proses normalisasi teks, khususnya ketika menangani data yang bersumber dari media sosial yang kerap mengandung bahasa tidak baku, singkatan, atau campur kode. Dengan adanya acuan resmi ini, model NLP dapat lebih mudah membedakan antara bahasa baku dan variasi informal

yang digunakan di ranah daring.

Dalam konteks pemrosesan bahasa alami, perbedaan-perbedaan ini menjadi tantangan penting ketika membangun sistem klasifikasi otomatis. Meskipun kedua bahasa sangat mirip secara struktural, model pemrosesan bahasa harus mampu membedakan karakteristik linguistik yang halus tersebut. Ketika data berasal dari media sosial, tantangan semakin kompleks karena adanya elemen bahasa gaul, singkatan, campur kode, serta ragam daerah.

2.2.5 Teks Pendek

Teks pendek adalah bentuk teks yang memiliki jumlah kata yang relatif sedikit, umumnya digunakan dalam media sosial, pesan instan, atau ulasan singkat. Teks pendek biasanya terdiri dari kurang dari 20 kata dan sering kali bersifat tidak lengkap secara sintaksis, namun tetap mengandung makna (Alsmadi & Gan, 2019). Ciri khas dari teks pendek meliputi minimnya konteks, banyaknya singkatan, serta penggunaan bahasa informal. Contohnya seperti tweet, komentar, atau status singkat di media sosial. Tantangan utama dalam memproses teks pendek adalah kesulitan dalam mengekstrak informasi semantik yang cukup untuk klasifikasi yang akurat.

Klasifikasi teks merupakan salah satu tugas fundamental dalam bidang pemrosesan bahasa alami (*Natural Language Processing*). Namun, ketika berhadapan dengan teks pendek seperti tweet, komentar, atau pesan singkat, tantangan yang dihadapi menjadi lebih kompleks dibandingkan dengan teks panjang. Hal ini disebabkan oleh keterbatasan konteks, kelangkaan informasi semantik, serta tingginya tingkat ambiguitas yang sering kali terdapat dalam teks pendek.

Teks pendek cenderung memiliki fitur yang sangat terbatas dan konteks yang minim, sehingga menyulitkan proses klasifikasi yang akurat. Masalah ini diperparah oleh penggunaan bahasa informal, singkatan, dan variasi ejaan yang umum ditemukan dalam komunikasi sehari-hari di media sosial. Untuk mengatasi tantangan ini, berbagai pendekatan telah dikembangkan, mulai dari metode berbasis pembelajaran mesin tradisional hingga teknik pembelajaran mendalam (*deep learning*) (Alsmadi & Gan, 2019).

Salah satu pendekatan yang menjanjikan adalah penggunaan model berbasis *transformer*, seperti *Bidirectional Encoder Representations from Transformers* (BERT). Model ini mampu memahami konteks kata dalam kalimat secara lebih baik dibandingkan dengan metode sebelumnya. (Zuo dkk., 2019) dalam survei mereka menunjukkan bahwa model berbasis *transformer* telah menunjukkan kinerja yang superior dalam berbagai tugas klasifikasi teks, termasuk pada teks pendek.

Selain itu, pendekatan lain yang telah digunakan untuk meningkatkan akurasi klasifikasi teks pendek adalah dengan memperluas ruang fitur melalui teknik ekstensi semantik. (Zuo dkk., 2019) mengusulkan metode yang menggabungkan model topik *Latent Dirichlet Allocation* (LDA) dengan *Convolutional Neural Network* (CNN) untuk memperkaya representasi teks pendek, yang terbukti meningkatkan kinerja klasifikasi.

Namun, meskipun berbagai pendekatan telah dikembangkan, klasifikasi teks pendek tetap menjadi tantangan, terutama untuk bahasa dengan sumber daya terbatas seperti Bahasa Indonesia dan Bahasa Malaysia. Oleh karena itu, penelitian lebih lanjut diperlukan untuk mengembangkan metode yang lebih efektif dalam mengatasi keterbatasan yang ada.

2.2.6 Media Sosial

Media sosial merupakan salah satu bentuk perkembangan teknologi komunikasi yang memungkinkan terjadinya interaksi sosial secara daring. Berbeda dengan media konvensional yang bersifat satu arah, media sosial dirancang untuk mendukung komunikasi dua arah yang bersifat interaktif dan *real-time*. (Widada, 2018) menjelaskan bahwa media sosial adalah media berbasis internet yang memungkinkan penggunaanya untuk saling berkomunikasi, berbagi informasi, dan membangun jejaring sosial secara mudah. Teknologi ini memanfaatkan platform berbasis *web* yang menjadikan komunikasi bersifat lebih dinamis, karena memungkinkan percakapan secara langsung antar pengguna dari berbagai lokasi.

Media sosial telah mengubah pola komunikasi masyarakat dari yang sebelumnya bersifat monolog, menjadi dialog terbuka antar banyak pengguna.

Melalui media sosial, batas antara ruang privat dan publik menjadi semakin kabur. Banyak pengguna secara sadar membagikan informasi pribadi seperti nama, tanggal lahir, latar belakang pendidikan, pekerjaan, hingga foto pribadi secara terbuka di internet. Fenomena ini menjadikan media sosial bukan hanya sebagai sarana komunikasi, tetapi juga sebagai media untuk mengekspresikan identitas diri.

Selain berperan dalam komunikasi personal, media sosial juga berkontribusi besar dalam penyebaran informasi secara luas. (Maxwell-Smith dkk., 2020) mengungkapkan bahwa penggunaan media sosial di Indonesia berkembang sangat pesat. Bahkan, Indonesia sempat menempati peringkat lima besar dunia dalam jumlah pengguna Twitter. Hal ini menunjukkan bahwa media sosial semakin diterima sebagai media informasi, bahkan mampu menggantikan peran media massa konvensional dalam menyampaikan berita dan data.

Tidak hanya sebagai media informasi, media sosial juga digunakan sebagai alat untuk mendukung aktivitas ekonomi digital. Banyak pelaku usaha yang memanfaatkan media sosial sebagai sarana promosi, penjualan, hingga layanan pelanggan. Kemudahan akses, jangkauan luas, dan sifatnya yang fleksibel menjadikan media sosial sebagai alat komunikasi yang sangat efektif di era digital.

Dalam konteks penelitian ini, media sosial berfungsi sebagai sumber data berupa teks pendek yang digunakan pengguna dalam komunikasi sehari-hari. Teks ini sering kali tidak baku dan mengandung campuran bahasa, sehingga menimbulkan tantangan dalam proses klasifikasi bahasa. Oleh karena itu, diperlukan pendekatan berbasis pembelajaran mesin seperti *Multilingual BERT* yang mampu memahami konteks bahasa secara lebih dalam untuk membedakan antara Bahasa Indonesia dan Bahasa Malaysia dalam teks yang digunakan di media sosial.

2.2.7 Evaluasi Model

Evaluasi model klasifikasi dilakukan untuk mengukur tingkat keberhasilan model dalam memprediksi label yang benar berdasarkan data uji. Metrik evaluasi ini memberikan gambaran kuantitatif mengenai performa model, baik dari sisi ketepatan prediksi maupun kemampuannya dalam mengenali setiap kelas bahasa.

Dalam penelitian ini digunakan empat metrik utama, yaitu akurasi, *precision*, *recall*, dan *F1-score*. Nilai dari setiap metrik tersebut dihitung berdasarkan jumlah prediksi benar dan salah pada masing-masing kelas yang dirangkum dalam *confusion matrix*.

Beberapa komponen penting dalam *confusion matrix* meliputi:

- *True Positive (TP)*: Prediksi benar ketika model mengklasifikasikan data sebagai positif dan label aslinya juga positif.
- *True Negative (TN)*: Prediksi benar ketika model mengklasifikasikan data sebagai negatif dan label aslinya juga negatif.
- *False Positive (FP)*: Prediksi salah ketika model mengklasifikasikan data sebagai positif padahal label aslinya negatif.
- *False Negative (FN)*: Prediksi salah ketika model mengklasifikasikan data sebagai negatif padahal label aslinya positif.

Dari keempat komponen tersebut, sejumlah metrik performa utama dapat dihitung sebagai berikut:

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN} \quad (2)$$

$$Precision = \frac{TP}{TP + FP} \quad (3)$$

$$Recall = \frac{TP}{TP + FN} \quad (4)$$


$$F1\ score = \frac{2 \times (precision \times recall)}{precision + recall} \quad (5)$$

BAB III

MATODE PENELITIAN

3.1 Metode Penelitian

Penelitian ini bertujuan untuk membangun sistem klasifikasi otomatis yang dapat membedakan antara Bahasa Indonesia dan Bahasa Malaysia dalam teks pendek yang diperoleh dari media sosial. Adapun langkah langkah yang harus dilakukan dalam penelitian ini untuk mencapai tujuan tersebut bisa ditunjukkan pada gambar 3.1 :



Gambar 3. 1 Alur Penelitian

Berdasarkan gambar 3.1 langkah -langkah yang akan dilakukan pada tahapan ini yaitu memulai dengan studi literatur, pengumpulan data, perancangan sistem, *preprocessing data* dan dilanjutkan pelatihan model, evaluasi model, kemudian dilanjutkan dengan tahap deployment, dan diakhiri dengan penarikan kesimpulan sebagai hasil akhir.

3.1.1 Studi Literatur

Tahap ini diawali dengan melakukan penelusuran berbagai sumber ilmiah, seperti jurnal, prosiding, skripsi, dan laporan penelitian yang relevan dengan klasifikasi bahasa, pemrosesan bahasa alami (NLP), serta penggunaan model *transformer* seperti BERT dan turunannya. Tinjauan literatur ini bertujuan untuk memahami pendekatan dan teknik terkini yang digunakan dalam klasifikasi teks multibahasa, serta menjajaki tantangan dalam membedakan Bahasa Indonesia dan Bahasa Malaysia yang memiliki kemiripan linguistik tinggi.

3.1.2 Pengumpulan Data

created_at	favorite_count	full_text	id_str	image_url	in_reply_to_screen_name
Fri May 30 23:57:25 +0000 2025	0	yaampun dedek senang lewat charitas gk kena la...	1928601673670254781	NaN	NaN
Fri May 30 23:56:09 +0000 2025	0	@gongfowurz hahaha halooo senang berkenalan de...	1928601356715061740	NaN	gongfowurz
Fri May 30 23:55:44 +0000 2025	2	apa kabar proses hukum 'orang-orang senang' ko...	1928601250443964908	NaN	NaN
Fri May 30 23:55:32 +0000 2025	0	Terima kasih buat cerita hangatnya Flo. Di sin...	1928601200410169554	NaN	NaN
Fri May 30 23:55:25 +0000 2025	0	@pjsunkiast dengan senang hati maw kakk	1928601169141682487	NaN	pjsunkiast

Gambar 3. 2 Pengumpulan Data


Pada gambar 3.2, data yang digunakan dalam penelitian ini diperoleh melalui proses pengumpulan langsung dari media sosial Twitter. Peneliti menggunakan pendekatan web scraping untuk mendapatkan data berupa teks pendek yang relevan dengan topik penelitian. Dalam hal ini, tweet dikumpulkan berdasarkan kata kunci


tertentu, seperti “senang”, dan dibatasi dalam rentang waktu dari 1 November 2024 hingga 30 Mei 2025. Pengambilan data difokuskan pada tweet yang menggunakan Bahasa Indonesia dan Bahasa Malaysia.

Seluruh proses scraping dilakukan di platform Google Colab, dan hasilnya disimpan dalam format CSV. Dataset ini mencakup berbagai atribut, seperti isi tweet, waktu unggahan, serta identitas pengguna. Data tersebut tidak diambil dari repositori terbuka seperti Kaggle, melainkan dikumpulkan secara mandiri agar sesuai dengan kebutuhan penelitian ini.

3.1.3 Perancangan Sistem

Peneliti pada tahap ini akan menentukan alur kerja system berupa *flowchart* yang akan memberikan gambaran dari alur sistem nantinya. Di mana metode ini nantinya akan melakukan klasifikasi bahasa menggunakan pendekatan *Multilingual BERT* (mBERT), yang ditujukan untuk membedakan antara Bahasa Indonesia dan Bahasa Malaysia pada teks pendek yang berasal dari media sosial, seperti yang terlihat pada gambar 3.3 :





Gambar 3. 3 *Flowchart* Perancangan Sistem

Gambar 3.3 menunjukkan *flowchart* sistem yang menggambarkan alur kerja dari proses klasifikasi teks pendek menggunakan metode *Multilingual BERT* (mBERT). Flowchart ini merinci tahapan-tahapan penting yang dilakukan selama proses penelitian, mulai dari pengumpulan data hingga menghasilkan hasil klasifikasi. Penjelasan masing-masing tahapan adalah sebagai berikut:

a. Pengumpulan Data

Pada tahap ini, data dikumpulkan melalui proses *scraping* dari media sosial

Twitter dengan memanfaatkan library Python, yaitu *snsrape*. Data yang diambil berupa cuitan pengguna Twitter yang berpotensi mengandung teks berbahasa Indonesia dan Malaysia.

b. Data Selection

Setelah data berhasil dikumpulkan, dilakukan proses seleksi data untuk menyaring cuitan yang relevan, serta menghapus data yang bersifat spam, duplikat, atau tidak mengandung informasi bahasa yang bisa diidentifikasi.

c. Preprocessing Data

Data teks yang sudah diseleksi selanjutnya diproses agar siap untuk dianalisis oleh model. Tahapan ini meliputi pembersihan teks (menghapus tanda baca, simbol, URL), konversi ke huruf kecil (*case folding*), dan normalisasi teks agar konsisten. Tujuan dari preprocessing adalah meningkatkan kualitas input yang akan diterima oleh model.

d. Pelabelan Data

Setelah teks dibersihkan, dilakukan pelabelan semi otomatis terhadap masing-masing data. Label yang digunakan adalah ID untuk Bahasa Indonesia dan MY untuk Bahasa Malaysia. Proses ini penting untuk memastikan bahwa model dapat belajar dari data yang sudah diklasifikasi dengan benar.

e. Split Data

Dataset yang sudah dilabeli kemudian dibagi menjadi dua bagian, yaitu data latih dan data uji. Pemisahan ini bertujuan untuk mengukur performa model secara objektif setelah pelatihan.

f. Model mBERT

Model yang digunakan dalam penelitian ini adalah *Multilingual BERT*, yaitu varian BERT yang telah dilatih pada berbagai bahasa termasuk Bahasa Indonesia dan Bahasa Malaysia. Model ini akan digunakan sebagai dasar untuk memahami konteks bahasa dalam teks.

g. Pelatihan Model

Proses pelatihan dilakukan menggunakan data latih yang telah disiapkan. Model mBERT akan belajar mengenali pola-pola bahasa dari data yang telah diberikan label, sehingga dapat mengklasifikasikan teks dengan lebih akurat.

h. Evaluasi Model

Setelah pelatihan selesai, model diuji menggunakan data uji untuk mengukur performanya. Metrik evaluasi seperti akurasi, precision, recall, dan *F1-score* digunakan untuk menilai seberapa baik model dalam mengklasifikasikan bahasa teks pendek.


i. Hasil

Berdasarkan evaluasi, hasil akhir dari model ditampilkan. Hasil ini akan menunjukkan efektivitas penerapan mBERT dalam mengklasifikasikan teks pendek ke dalam dua bahasa target.

j. Selesai

Tahapan terakhir adalah penutupan proses, yang menyimpulkan bahwa sistem telah berhasil menjalankan fungsinya sesuai dengan tujuan penelitian.

3.1.4 *Preprocessing Data*



Gambar 3. 4 *Flowchart Preprocessing*

Pada gambar 3.4 perancangan model, proses preprocessing data menjadi langkah penting untuk memastikan kualitas input yang akan diterima oleh model *Multilingual BERT* (mBERT). Dataset yang digunakan berupa teks pendek hasil scraping dari media sosial Twitter yang mengandung bahasa Indonesia dan bahasa Malaysia.

Proses preprocessing ini diawali dengan pembersihan data dari karakter-karakter yang tidak dibutuhkan, seperti tagar, tautan (URL), simbol, dan tanda baca yang tidak relevan. Selain itu, teks dikonversi ke huruf kecil (*case folding*) untuk menghindari duplikasi kata karena perbedaan kapitalisasi. Proses normalisasi juga diterapkan dengan mengubah kata-kata tidak baku menjadi bentuk yang lebih standar, terutama untuk menangani gaya penulisan khas media sosial.

Langkah tokenisasi diterapkan untuk memecah kalimat menjadi satuan kata, yang akan menjadi representasi input bagi model mBERT. Seluruh proses preprocessing dilakukan secara sistematis untuk menghasilkan data teks yang bersih, terstruktur, dan siap untuk digunakan dalam proses pelatihan model. Dengan tahapan ini, diharapkan model dapat lebih mudah mengenali pola linguistik dalam bahasa Indonesia dan Malaysia sehingga menghasilkan akurasi klasifikasi yang optimal.

3.1.5 Pelatihan Model

Setelah tahap preprocessing data selesai dilakukan, langkah selanjutnya adalah melakukan pelatihan model menggunakan arsitektur *Multilingual BERT* (mBERT). Model mBERT merupakan varian dari BERT yang telah dilatih pada lebih dari 100 bahasa, termasuk bahasa Indonesia dan bahasa Malaysia, sehingga cocok digunakan dalam penelitian ini. Sebelum pelatihan dilakukan, data yang telah dikumpulkan dibagi menjadi dua bagian, yaitu data latih dan data uji. Dalam penelitian ini, data dibagi dengan proporsi 80% untuk pelatihan dan 20% untuk pengujian. Pembagian ini bertujuan agar model dapat dilatih secara optimal menggunakan sebagian besar data, sekaligus diuji kemampuannya dalam mengklasifikasikan data baru yang belum pernah dilihat sebelumnya.

Pada proses pelatihan, model mBERT digunakan sebagai lapisan dasar yang telah dipra-latih (*pretrained*), kemudian ditambahkan lapisan klasifikasi di atasnya.

Lapisan tambahan ini berupa *Dense layer* dengan jumlah *neuron* yang disesuaikan dengan jumlah kelas yang diprediksi, yaitu bahasa Indonesia dan bahasa Malaysia. Fungsi aktivasi yang digunakan adalah *sigmoid* karena klasifikasi bersifat multi-label. Selama proses pelatihan, bobot dari lapisan mBERT dapat dibekukan (*frozen*) terlebih dahulu untuk memfokuskan pelatihan pada lapisan klasifikasi. Setelah itu, dilakukan *fine-tuning* secara bertahap terhadap seluruh model agar dapat menyesuaikan dengan karakteristik data teks pendek dari media sosial. Proses pelatihan menggunakan optimizer Adam dan fungsi kerugian *categorical crossentropy*, dengan pemantauan metrik akurasi untuk mengevaluasi kinerja model selama pelatihan berlangsung.

3.1.6 Evaluasi Model

Setelah proses pelatihan selesai dilakukan, tahap selanjutnya adalah evaluasi model untuk mengukur kinerja dan kemampuan generalisasi dalam mengklasifikasikan teks pendek berbahasa Indonesia dan Malaysia. Evaluasi ini dilakukan menggunakan data uji yang telah dipisahkan sebelumnya saat proses pembagian data. Beberapa metrik evaluasi yang digunakan meliputi nilai akurasi, serta analisis lebih lanjut melalui *confusion matrix* dan *classification report*. *Confusion matrix* digunakan untuk melihat seberapa baik model dalam membedakan antara teks berbahasa Indonesia dan Malaysia berdasarkan prediksi yang dihasilkan. Sementara itu, *classification report* menyajikan metrik seperti precision, recall, dan *F1-score* untuk masing-masing kelas bahasa. Metrik-metrik ini membantu dalam memahami kekuatan dan kelemahan model secara lebih menyeluruh.

Melalui tahapan evaluasi ini, diperoleh gambaran mengenai sejauh mana model *Multilingual BERT* mampu mengenali dan mengklasifikasikan teks pendek dari kedua bahasa dengan akurat dan konsisten. Hasil evaluasi ini juga menjadi dasar untuk mempertimbangkan peningkatan model di tahap pengembangan berikutnya. Setelah proses pelatihan selesai dilakukan, tahap selanjutnya adalah evaluasi model untuk mengukur kinerja dan kemampuan generalisasi dalam mengklasifikasikan teks pendek berbahasa Indonesia dan Malaysia. Evaluasi ini

dilakukan menggunakan data uji yang telah dipisahkan sebelumnya saat proses pembagian data.

Beberapa metrik evaluasi yang digunakan meliputi nilai akurasi, *precision*, *recall*, dan *F1-score* serta analisis lebih lanjut melalui *confusion matrix* dan *classification report* yang dihitung menggunakan rumus pada Persamaan (2) hingga (5) di Bab 2. *Confusion matrix* digunakan untuk melihat seberapa baik model dalam membedakan antara teks berbahasa Indonesia dan Malaysia berdasarkan prediksi yang dihasilkan. Sementara itu, *classification report* menyajikan metrik seperti *precision*, *recall*, dan *F1-score* untuk masing-masing kelas bahasa. Metrik-metrik ini membantu dalam memahami kekuatan dan kelemahan model secara lebih menyeluruh.

Melalui tahapan evaluasi ini, diperoleh gambaran mengenai sejauh mana model *Multilingual BERT* mampu mengenali dan mengklasifikasikan teks pendek dari kedua bahasa dengan akurat dan konsisten. Hasil evaluasi ini juga menjadi dasar untuk mempertimbangkan peningkatan model di tahap pengembangan berikutnya.

3.1.7 Deployment Model

Setelah proses pelatihan dan pengujian model *Multilingual BERT* selesai dilakukan, langkah berikutnya adalah menerapkan model tersebut ke dalam bentuk aplikasi berbasis web. Tujuannya adalah agar model dapat digunakan secara langsung oleh pengguna untuk melakukan klasifikasi teks pendek berbahasa Indonesia dan Malaysia. Aplikasi ini dibuat menggunakan Streamlit karena cukup sederhana dan praktis dalam membangun antarmuka web. Pengguna hanya perlu memasukkan teks ke dalam kolom yang tersedia, kemudian sistem akan secara otomatis memproses dan menampilkan hasil klasifikasinya. Teks yang dimasukkan terlebih dahulu melalui proses pembersihan dan penyesuaian sebelum diprediksi oleh model.


Hasil klasifikasi akan langsung muncul di layar, sehingga pengguna bisa mengetahui apakah teks tersebut menggunakan bahasa Indonesia atau Malaysia. Dengan adanya aplikasi ini, proses pengujian menjadi lebih mudah dan pengguna dapat mencoba sistem tanpa harus memahami cara kerja model di baliknya.

Aplikasi ini juga disusun secara terstruktur agar ke depannya dapat dikembangkan lebih lanjut sesuai kebutuhan.

3.2 Analisis Sistem

Pada analisis sistem penelitian ini, penulis membangun sistem klasifikasi bahasa untuk membedakan Bahasa Indonesia dan Bahasa Malaysia pada teks pendek dari media sosial menggunakan metode *Multilingual BERT* (mBERT). Untuk merancang alur sistem, diperlukan sebuah *flowchart* yang menunjukkan langkah-langkah bagaimana sistem berjalan. Pada Gambar 3.5 merupakan *flowchart* rancangan alur sistem yang akan dibangun:





Gambar 3. 5 *Flowchart* Alur Kerja Sistem

Gambar 3.5 merupakan *flowchart* tahapan alur kerja sistem yang dilakukan dengan langkah-langkah berikut:

1. Pengguna mengakses antarmuka aplikasi web yang telah dibuat menggunakan *Streamlit*. Halaman utama menampilkan kolom input untuk memasukkan teks pendek yang akan diprediksi.
2. Pengguna memasukkan teks pendek yang diambil dari media sosial atau diketik langsung pada kolom input.

3. Sistem melakukan preprocessing data untuk membersihkan teks dari karakter tidak diperlukan (tanda baca, URL, simbol), mengubah ke huruf kecil (*case folding*), dan normalisasi kata.
4. Data diproses oleh model mBERT, yang telah dilatih sebelumnya untuk membedakan Bahasa Indonesia dan Bahasa Malaysia. Model akan menghasilkan probabilitas untuk masing-masing bahasa.
5. Sistem menampilkan hasil klasifikasi berupa label bahasa dengan probabilitas tertinggi beserta nilai probabilitas Bahasa Indonesia dan Bahasa Malaysia.
6. Proses selesai, pengguna dapat kembali ke tahap awal untuk memasukkan teks lainnya.

3.3 Identifikasi Perangkat Lunak

Pada tahap analisis kebutuhan, peneliti mengidentifikasi perangkat lunak dan pustaka (*library*) yang diperlukan untuk membangun sistem klasifikasi bahasa ini. Tujuannya adalah memastikan seluruh proses, mulai dari input teks hingga keluaran hasil klasifikasi, dapat berjalan sesuai rancangan. Adapun perangkat lunak dan pustaka (*library*) yang digunakan adalah sebagai berikut:

1. *Python*

Python merupakan bahasa pemrograman tingkat tinggi yang bersifat *open source* dengan sintaks sederhana dan mudah dibaca, sehingga banyak digunakan dalam pengembangan aplikasi, analisis data, hingga *machine learning*. Bahasa ini mendukung berbagai paradigma pemrograman dan memiliki ekosistem pustaka yang kaya. Dalam penelitian ini digunakan *Python* versi 3.12.4 yang dirilis oleh *Python Software Foundation* (PSF) pada 6 Juni 2024. Versi ini merupakan rilis pemeliharaan seri 3.12 yang menghadirkan perbaikan bug, peningkatan performa, fleksibilitas parsing pada *f-string*, serta dukungan API baru untuk *debugging*, sehingga lebih stabil dan kompatibel dengan pustaka yang digunakan seperti PyTorch, Transformers, Pandas, dan NumPy.

2. *Google Colaboratory*

Google Colaboratory (*Colab*) merupakan layanan berbasis cloud dari Google yang memungkinkan pengguna menulis, mengembangkan, dan menjalankan kode

Python secara interaktif langsung melalui browser tanpa memerlukan instalasi lokal. Platform ini menyediakan akses gratis ke *Graphics Processing Unit* (GPU) dan *Tensor Processing Unit* (TPU) yang mempercepat proses komputasi, sehingga sangat mendukung pelatihan model *machine learning* seperti mBERT yang digunakan dalam penelitian ini. Selain itu, Colab terintegrasi dengan *Google Drive*, memudahkan penyimpanan, pengelolaan, dan berbagi *notebook* yang berisi kode dan dokumentasi penelitian secara efisien.

3. Pandas

Pandas merupakan *library Python* yang menyediakan struktur data dan fungsi analisis yang efisien untuk pengolahan data. Dalam penelitian ini, Pandas digunakan untuk membaca dataset hasil *scraping* dari media sosial dalam format CSV, membersihkan data dari nilai yang hilang atau tidak relevan, menghapus data duplikat, serta melakukan pengelompokan berdasarkan label bahasa. Selain itu, Pandas juga digunakan untuk menyimpan kembali data yang telah diproses ke dalam format CSV agar siap digunakan pada tahap pelatihan dan evaluasi model mBERT.

4. Numpy

NumPy (*Numerical Python*) merupakan *library Python* yang dirancang untuk mendukung komputasi numerik secara cepat dan efisien. Pustaka ini menyediakan struktur data *array* multidimensi dan berbagai fungsi matematis untuk operasi seperti penjumlahan, perkalian matriks, dan manipulasi vektor. Dalam penelitian ini, NumPy digunakan pada tahap *pre-processing* untuk mengubah data teks yang telah melalui proses tokenisasi menjadi representasi numerik, sehingga dapat diproses oleh model mBERT, serta mempercepat perhitungan pada operasi matriks selama pelatihan dan evaluasi model.

5. PyTorch

PyTorch merupakan *framework* pembelajaran mesin berbasis *open source* yang digunakan dalam penelitian ini untuk membangun dan melatih model mBERT. PyTorch menyediakan antarmuka yang fleksibel untuk mendefinisikan arsitektur jaringan saraf tiruan, menjalankan proses *forward* dan *backward propagation*, serta mengatur proses pelatihan dan evaluasi model. Dengan dukungan GPU, PyTorch

mampu mempercepat komputasi pada pelatihan model klasifikasi bahasa, sehingga proses pengolahan data berukuran besar dapat dilakukan secara lebih efisien.

6. *Hugging Face Transformers*

Hugging Face Transformers merupakan *library Python* yang menyediakan berbagai model bahasa *pre-trained* berbasis arsitektur *transformer*, termasuk *Multilingual BERT* (mBERT) yang digunakan dalam penelitian ini. Pustaka ini dimanfaatkan untuk memuat model mBERT, melakukan tokenisasi teks menggunakan *AutoTokenizer*, serta melakukan *fine-tuning* pada model klasifikasi agar mampu membedakan teks berbahasa Indonesia dan Malaysia secara akurat. Keunggulan pustaka ini terletak pada kemudahan akses ke model bahasa canggih yang telah dilatih dengan data berskala besar, sehingga dapat langsung digunakan atau disesuaikan kembali sesuai kebutuhan penelitian tanpa harus melatih model dari awal.

7. *Scikit-learn* (sklearn)

Scikit-learn merupakan *library Python* yang digunakan dalam penelitian ini untuk mendukung tahapan pembelajaran mesin yang tidak ditangani langsung oleh PyTorch. Pustaka ini dimanfaatkan untuk melakukan pembagian dataset menggunakan *train-test split*, menghitung metrik evaluasi seperti akurasi, *precision*, *recall*, *F1-score*, serta menampilkan *confusion matrix* untuk menganalisis performa model mBERT. Dengan kemampuannya yang ringan, terstruktur, dan kompatibel dengan pustaka numerik seperti NumPy dan Matplotlib, Scikit-learn membantu proses evaluasi model menjadi lebih cepat dan sistematis.

8. *Langdetect*

Langdetect merupakan *library Python* yang digunakan untuk mendeteksi bahasa dari teks secara otomatis. *Library* ini mampu mengenali lebih dari 50 bahasa dengan pendekatan berbasis *n-gram* karakter. Dalam penelitian ini, *langdetect* dimanfaatkan sebagai langkah validasi awal untuk memastikan bahwa data hasil *scraping* dari media sosial benar-benar berisi teks berbahasa Indonesia atau Malaysia sebelum diproses lebih lanjut. Penggunaan *langdetect* membantu meminimalkan kesalahan klasifikasi akibat adanya data berbahasa campuran atau

bahasa di luar cakupan penelitian, sehingga kualitas dataset yang digunakan pada tahap pelatihan model mBERT dapat terjaga.

9. *Library Glob, Os, Re dan String*

Glob, *os*, *re*, dan *string* merupakan *library* pendukung yang digunakan untuk membantu proses manajemen file dan manipulasi teks. *Glob* berfungsi untuk melakukan pencarian dan pemilihan file berdasarkan pola tertentu di dalam direktori, misalnya untuk memuat dataset atau file hasil proses pelatihan. *Os* digunakan untuk berinteraksi dengan sistem operasi, seperti mengatur path file, membuat folder baru, atau memeriksa keberadaan file. *Re* (*regular expressions*) dimanfaatkan untuk mendeteksi dan menghapus pola teks tertentu, misalnya URL, simbol, atau karakter yang tidak relevan, sehingga data menjadi lebih bersih sebelum diproses oleh model. Sedangkan *string* menyediakan berbagai fungsi untuk memanipulasi teks, seperti menghapus tanda baca atau mengubah format huruf, yang berguna dalam tahap *pre-processing* data.

10. *Collection (defaultdict)*

Collections (defaultdict) merupakan pustaka Python yang menyediakan tipe data tambahan untuk mempermudah pengelolaan struktur data. Dalam penelitian ini digunakan tipe data *defaultdict*, yaitu turunan dari *dictionary* yang secara otomatis memberikan nilai awal (*default value*) pada kunci yang belum ada. Fungsionalitas ini dimanfaatkan untuk mengelompokkan data hasil analisis, seperti perhitungan jumlah label atau distribusi kategori bahasa, sehingga proses pengolahan data menjadi lebih efisien dan mengurangi kebutuhan pengecekan manual terhadap keberadaan kunci.

11. *Tqdm*

Tqdm merupakan pustaka Python yang digunakan untuk menampilkan *progress bar* secara real-time pada proses yang memerlukan iterasi panjang, seperti pelatihan model atau pemrosesan dataset dalam jumlah besar. Penggunaan *progress bar* ini memberikan informasi visual mengenai persentase kemajuan proses, estimasi waktu yang tersisa, serta jumlah iterasi yang telah dijalankan. Dengan demikian, pengguna dapat memantau jalannya eksekusi program dengan lebih mudah dan efektif.

12. *Matplotlib dan Seaborn*

Matplotlib dan *Seaborn* merupakan pustaka visualisasi data yang digunakan untuk menyajikan informasi hasil analisis dalam bentuk grafik. *Matplotlib* menyediakan antarmuka fleksibel untuk membuat berbagai jenis grafik seperti *line chart*, *bar chart*, dan *scatter plot*. Sementara itu, *Seaborn* dibangun di atas *Matplotlib* dengan menyediakan fungsi visualisasi tingkat tinggi yang lebih estetik dan ringkas, seperti *heatmap* dan *countplot*. Dalam penelitian ini, kedua pustaka digunakan untuk menampilkan grafik *training loss*, *accuracy*, serta *heatmap confusion matrix*, sehingga memudahkan interpretasi performa model secara visual.

13. *FastText*

FastText merupakan pustaka pembelajaran mesin yang dikembangkan oleh Facebook AI Research (FAIR) dan dirancang untuk pemrosesan bahasa alami yang efisien. Pustaka ini mendukung pelatihan dan penerapan model klasifikasi teks maupun representasi kata (*word embedding*) dengan kecepatan tinggi. Dalam penelitian ini, *fastText* digunakan untuk memuat model pralatih *lid.176.bin* yang mampu mendeteksi lebih dari 170 bahasa, termasuk Bahasa Indonesia dan Bahasa Malaysia. Hasil deteksi ini dimanfaatkan sebagai validasi awal terhadap data teks sebelum masuk ke tahap pelabelan dan pelatihan model mBERT, sehingga membantu meminimalkan kesalahan klasifikasi akibat adanya data yang tidak sesuai bahasa target.

14. *Visual Studio Code*

Visual Studio Code (VS Code) digunakan dalam penelitian ini sebagai *text editor* utama untuk menulis dan mengelola kode program. VS Code merupakan editor kode sumber yang ringan, cepat, dan mendukung berbagai bahasa pemrograman serta *framework* yang relevan dengan pengembangan sistem klasifikasi berbasis mBERT. Editor ini bersifat *multiplatform* sehingga dapat dijalankan di berbagai sistem operasi, serta memiliki ekosistem ekstensi yang kaya untuk mendukung fitur seperti *IntelliSense* (auto-completion), debugging, integrasi Git, dan linting. Dengan antarmuka yang sederhana namun fungsional, VS Code membantu mempercepat proses pengembangan dan memudahkan pengelolaan proyek penelitian ini secara efisien.

15. *Streamlit*

Streamlit merupakan *framework* berbasis *Python* yang bersifat *open source* dan dirancang untuk mempermudah pembuatan aplikasi web interaktif, khususnya dalam bidang *data science* dan *machine learning*. Dalam penelitian ini, *Streamlit* digunakan untuk membangun antarmuka web yang memungkinkan pengguna memasukkan judul dan abstrak teks untuk diklasifikasikan menggunakan model mBERT yang telah dilatih. Keunggulan *Streamlit* terletak pada kemampuannya mengintegrasikan kode *Python* secara langsung ke dalam tampilan web tanpa memerlukan pengetahuan mendalam tentang pengembangan web konvensional, sehingga hasil klasifikasi dapat ditampilkan secara *realtime* dengan visualisasi yang sederhana namun informatif.

3.4 Perancangan *User Interface*

Berikut ini merupakan rancangan desain dari sistem yang akan digunakan pada penelitian ini:

1. Halaman Utama

Halaman utama merupakan antarmuka awal yang pertama kali dilihat oleh pengguna saat mengakses sistem klasifikasi Bahasa Indonesia vs Malaysia.



Sistem Klasifikasi

← → ↻ http://localhost:8501/

Klasifikasi Bahasa Indonesia Vs Bahasa Malaysia

Model : Multilingual BERT

Masukkan Teks Pendek

Klasifikasikan

Gambar 3. 6 Halaman Utama

Gambar 3.6 menampilkan halaman utama sistem dengan judul "Klasifikasi Bahasa Indonesia vs Bahasa Malaysia". Di bawah judul terdapat keterangan singkat mengenai model yang digunakan, yaitu *Multilingual BERT* (mBERT), yang berfungsi untuk mengklasifikasikan bahasa dari teks pendek yang dimasukkan pengguna. Pada halaman ini tersedia satu kolom input untuk mengetikkan teks yang akan diuji, lengkap dengan *placeholder* yang memandu pengguna dalam memasukkan data. Setelah teks dimasukkan, pengguna dapat menekan tombol "Klasifikasikan" untuk memulai proses analisis. Sistem kemudian akan memproses input tersebut menggunakan model mBERT dan menampilkan hasil klasifikasi beserta probabilitas untuk setiap kategori bahasa. Desain halaman dibuat sederhana dan fokus agar mudah digunakan oleh pengguna tanpa memerlukan pengetahuan teknis mendalam.

2. Halaman Klasifikasi

Halaman ini menampilkan hasil klasifikasi dari teks yang telah dimasukkan oleh pengguna seperti terlihat pada gambar 3. 7 dibawah ini.



Sistem Klasifikasi

← → ↻ http://localhost:8501/

Klasifikasi Bahasa Indonesia Vs Bahasa Malaysia

Model : Multilingual BERT

Masukkan Teks Pendek

Sy Nak Makan

Klasifikasikan

Hasil Klasifikasi : Bahasa Malaysia

Probabilitas Bahasa Indonesia: 0.02%

Probabilitas Bahasa Malaysia: 99.98%

Gambar 3. 7 Halaman Klasifikasi

Gambar 3.7 menunjukkan tampilan hasil klasifikasi, di mana sistem menampilkan label bahasa yang terdeteksi (Bahasa Indonesia atau Bahasa

Malaysia) beserta nilai probabilitas untuk masing-masing bahasa. Nilai probabilitas disajikan dalam bentuk persentase, dengan bahasa yang memiliki nilai tertinggi dianggap sebagai hasil klasifikasi utama. Tampilan ini juga menyajikan urutan peringkat bahasa berdasarkan nilai probabilitas, sehingga memudahkan pengguna dalam memahami distribusi kemungkinan hasil klasifikasi. Dengan desain yang sederhana namun informatif, pengguna dapat langsung mengetahui hasil analisis secara cepat, tanpa memerlukan langkah tambahan. Penyajian hasil ini bertujuan untuk memastikan akurasi informasi dan meminimalkan kebingungan pengguna dalam menafsirkan keluaran sistem.



BAB IV

HASIL DAN ANALISIS PENELITIAN

4.1 Hasil Penelitian

Penelitian ini menghasilkan sebuah sistem klasifikasi bahasa untuk membedakan teks pendek berbahasa Indonesia dan/atau Bahasa Malaysia menggunakan metode *Multilingual BERT* (mBERT) dengan *pendekatan multi-label classification*. Proses penelitian diawali dengan mengumpulkan dataset yang bersumber dari platform media sosial Twitter, diambil dalam bentuk teks pendek yang terdiri dari minimal 1 kata dan maksimal 20 kata. Sebelum masuk ke tahap pelabelan, dilakukan validasi awal menggunakan model *fastText* pralatih lid.176.bin untuk memastikan teks yang dikumpulkan sesuai dengan bahasa target penelitian.

Data yang telah lolos validasi kemudian melalui proses seleksi dan *preprocessing*, mencakup pembersihan karakter yang tidak diperlukan (tanda baca, URL, simbol, emoji), *case folding*, normalisasi kata tidak baku, serta tokenisasi. Setelah tahap ini, diperoleh total 56.701 data teks dengan distribusi Bahasa Indonesia sebanyak 27.483 data, Bahasa Malaysia sebanyak 8.116 data dan data campuran atau yang termasuk kedalam kedua bahasa tersebut sebanyak 21.102. Perbedaan jumlah yang relatif seimbang ini meminimalkan risiko bias terhadap salah satu kelas bahasa.

Selanjutnya, data dibagi menjadi 80% data latih dan 20% data uji. Model mBERT digunakan sebagai *pretrained model* yang kemudian dilakukan *fine-tuning* untuk tugas klasifikasi multi-label dua bahasa (Bahasa Indonesia dan Bahasa Malaysia). Proses pelatihan dilakukan selama 20 *epoch* menggunakan *optimizer* Adam dan fungsi kerugian *Binary Crossentropy* yang sesuai untuk *multi-label classification*. Selama pelatihan, dilakukan pemantauan terhadap metrik akurasi dan *loss* untuk memastikan model belajar secara optimal.

Setelah pelatihan selesai, model diuji menggunakan data uji dan dievaluasi menggunakan metrik akurasi, *precision*, *recall*, *F1-score*, serta *multilabel confusion matrix* untuk melihat performa per kelas. Hasil evaluasi menunjukkan bahwa model

mampu mengenali kedua bahasa dengan akurasi tinggi dan performa yang konsisten pada tiap label.

Tahap akhir penelitian adalah implementasi model dalam bentuk aplikasi berbasis web menggunakan *framework Streamlit*. Aplikasi ini memungkinkan pengguna memasukkan teks pendek yang ingin diuji, kemudian sistem akan memproses input tersebut melalui tahap *preprocessing*, memprediksi menggunakan model mBERT yang telah dilatih, dan menampilkan hasil berupa label bahasa yang terdeteksi beserta nilai probabilitasnya. Aplikasi dapat dijalankan secara lokal maupun diunggah ke server, sehingga memudahkan pengguna untuk mengakses dan mencoba sistem secara langsung.

4.1.1 Hasil Pengumpulan data

no	full_text	id	my
1	ohhh taeyong pernah ddk malaysia ke no wonder he said back in malaysia aaaa comel	0	1
2	i keep thinking about how smart you are siss pose comel tapi still jaga batas	0	1
3	comel je	0	1
4	topic suho eat nasi lemak he pronounce so cuteeee sayang can u make it exolbunnyzen	0	1
5	wait for meee i got little legs macam kucen munchkin aaaa comel	0	1
6	comel je kan baca jongdae hes so cute	0	1
7	alicia comel gila	0	1
8	haha comel	0	1
10	comel giler pls jgn comel2 satgi kita minat awak	0	1
11	kucing comel awak tak	0	1
13	yihhh comel	0	1
14	argh comel mak nak kahwin hahah	0	1
15	comel gila hello choi seungcheol	0	1

Gambar 4. 1 Dataet yang telah di kumpulkan

Pada Gambar 4.1 diperlihatkan bahwa dataset yang digunakan dalam penelitian ini berasal dari hasil *web scraping* platform media sosial Twitter menggunakan pustaka *snsrape*. Dataset yang dikumpulkan berupa teks pendek yang ditulis oleh pengguna Twitter dalam Bahasa Indonesia dan/atau Bahasa Malaysia, dengan panjang teks minimal 1 kata dan maksimal 20 kata sesuai batasan penelitian. Sebelum proses pelabelan, dilakukan validasi awal menggunakan model *fastText* pralatih lid.176.bin untuk memastikan teks yang dikumpulkan sesuai bahasa target penelitian.

Proses pengumpulan dilakukan dengan kata kunci umum yang digunakan di kedua bahasa, seperti “senang”, “boleh”, “bisa”, “tewas”, dan lainnya, sehingga mencakup variasi bahasa formal maupun bahasa gaul yang sering digunakan di media sosial. Dataset awal disimpan dalam format CSV/XLSX dengan kolom utama:

- *full_text*: berisi isi teks pendek yang dikumpulkan dari Twitter.
- *id*: label yang menunjukkan keberadaan Bahasa Indonesia dalam teks (1 = ada, 0 = tidak ada).
- *my*: label yang menunjukkan keberadaan Bahasa Malaysia dalam teks (1 = ada, 0 = tidak ada).

Dari hasil pengumpulan data, diperoleh total 56.701 teks pendek. Distribusi label menunjukkan bahwa terdapat 27.483 data ($\pm 48,47\%$) berbahasa Indonesia saja, 8.116 data ($\pm 14,31\%$) berbahasa Malaysia saja, serta 21.102 data ($\pm 37,22\%$) yang merupakan campuran antara Bahasa Indonesia dan Bahasa Malaysia. Karena sistem menggunakan pendekatan *multi-label classification*, satu teks dapat memiliki label ganda, sehingga memungkinkan adanya data campuran yang memuat kosakata dari kedua bahasa.

Tabel 4. 1 Distribusi *Dataset* Bahasa Indonesia dan Bahasa Malaysia

Label	Bahasa	Jumlah Data	Persentase	Keterangan
ID	Indonesia saja	27.483	48,47%	Teks pendek yang hanya mengandung Bahasa Indonesia, baik dalam bentuk formal maupun informal (gaul).
MY	Malaysia saja	8.116	14,31%	Teks pendek yang hanya mengandung Bahasa Malaysia, baik formal maupun bahasa sehari-hari khas Malaysia.
Campuran	Indonesia–Malaysia	21.102	37,22%	Teks pendek yang mengandung kosakata dari kedua bahasa secara

Label	Bahasa	Jumlah Data	Persentase Keterangan
-------	--------	----------------	-----------------------

bersamaan, mencerminkan adanya kata-kata serumpun atau campuran gaya bahasa yang sulit dibedakan.

Karena sistem menggunakan pendekatan *multi-label classification*, satu teks dapat memiliki label Bahasa Indonesia dan Bahasa Malaysia secara bersamaan. Hal ini memungkinkan adanya data campuran yang mengandung kosakata dari kedua bahasa. Dataset yang diperoleh mencerminkan variasi kosakata yang luas, termasuk kata-kata serumpun yang memiliki arti berbeda di kedua bahasa, sehingga menjadi tantangan tersendiri dalam proses klasifikasi. Adanya data campuran ini menunjukkan variasi kosakata yang luas serta penggunaan kata-kata serumpun yang terkadang memiliki arti berbeda tergantung konteks. Hal ini menjadi tantangan tersendiri dalam proses klasifikasi, terutama pada teks dari media sosial yang sering menggunakan gaya bahasa tidak baku.

4.1.2 Hasil *Preprocessing Data*

Tahap *preprocessing* dilakukan untuk menyiapkan data sebelum digunakan dalam pelatihan model. Tujuan dari tahap ini adalah membersihkan, menormalkan, dan mengubah teks menjadi format yang dapat dipahami oleh model *Multilingual BERT* (mBERT). Mengingat data berasal dari media sosial Twitter yang memiliki karakteristik *noisy* dan tidak terstruktur, proses ini menjadi langkah penting agar kualitas data yang digunakan dalam pelatihan tetap terjaga. Teks mentah dari media sosial sering kali memuat elemen yang tidak relevan atau bahkan mengganggu pembelajaran model, sehingga diperlukan serangkaian langkah pengolahan yang sistematis.

Langkah awal adalah pembersihan karakter khusus. Pada tahap ini, unsur-unsur yang tidak berkontribusi terhadap klasifikasi bahasa dihapus dari teks. Elemen yang dihapus mencakup tautan atau URL yang umum ditemukan pada unggahan Twitter, *mention* atau penanda akun @username, serta *hashtag* (#) beserta simbolnya dengan kemungkinan mempertahankan kata di belakangnya setelah tanda # dihapus. Tanda baca berlebihan seperti “!!!” atau “???” yang hanya menambah

noise juga dihapus, begitu pula angka yang tidak berkaitan dengan isi teks, simbol atau karakter khusus seperti \$, %, dan &, serta emoji yang tidak dikonversi menjadi deskripsi teks karena fokus penelitian ini adalah pada konten teks asli. Proses ini dijalankan secara otomatis menggunakan *Regular Expressions (Regex)* di Python melalui pustaka *re* untuk memastikan hasil yang konsisten di seluruh data.

Tahap berikutnya adalah *case folding*, yakni mengubah semua huruf menjadi huruf kecil (*lowercase*) agar kata yang sama tidak dianggap berbeda hanya karena kapitalisasi, misalnya “Boleh” dan “boleh”. Setelah itu dilakukan normalisasi kata tidak baku. Mengingat teks di media sosial sering menggunakan singkatan atau ejaan tidak baku, diperlukan konversi ke bentuk baku dengan memanfaatkan *slang dictionary* yang dibuat secara manual berdasarkan temuan dari data. Contoh konversi termasuk: “sy” → “saya”, “x” (Bahasa Malaysia) → “tidak”, “gk” atau “ga” (Bahasa Indonesia) → “tidak”, serta “u” → “kamu”. Langkah ini membantu memastikan model memiliki representasi yang konsisten terhadap kata yang sama meskipun penulisannya bervariasi.

Setelah pembersihan dan normalisasi, dilakukan penghapusan spasi ganda yang biasanya muncul akibat penghapusan karakter tertentu, sehingga teks menjadi lebih rapi dan terstruktur. Teks bersih kemudian melalui tahap tokenisasi menggunakan *AutoTokenizer* dari pustaka *HuggingFace Transformers* yang mendukung *Multilingual BERT*. Metode tokenisasi yang digunakan adalah *WordPiece*, yang memecah kata menjadi unit kata (*sub-word*). Dengan cara ini, kata yang tidak terdapat dalam *vocabulary mBERT* tetap bisa diproses dengan memecahnya menjadi potongan kata yang dikenali.

Agar seluruh input memiliki panjang yang konsisten, dilakukan proses *padding* dan *truncating*. *Padding* menambahkan token khusus [PAD] pada teks yang panjangnya kurang dari batas maksimum, sedangkan *truncating* memotong teks yang melebihi batas maksimal token, yaitu 128 token. Tahap terakhir adalah pelabelan *multi-label*. Pada tahap ini, label bahasa diubah ke format numerik biner terpisah:

- Kolom id : 1 jika teks mengandung Bahasa Indonesia, 0 jika tidak.
- Kolom my : 1 jika teks mengandung Bahasa Malaysia, 0 jika tidak.

Format ini memungkinkan sebuah teks memiliki kedua label sekaligus jika mengandung campuran Bahasa Indonesia dan Bahasa Malaysia.

Hasil akhir *preprocessing* disimpan dalam file XLSX yang memuat dua komponen utama:

- *text_clean* : teks bersih hasil pembersihan dan normalisasi.
- *id* dan *my* :label bahasa dalam format numerik multi-label.

Secara keseluruhan, *preprocessing* mengubah data mentah yang semula penuh *noise* menjadi teks yang bersih, konsisten, dan siap diproses oleh mBERT. Dengan data yang lebih terstruktur, model memiliki peluang lebih besar untuk mempelajari ciri khas linguistik dari Bahasa Indonesia dan Bahasa Malaysia, meskipun keduanya memiliki banyak kesamaan kosakata dan pola kalimat.

4.1.3 Implementasi Pelatihan Model

Setelah proses *preprocessing* selesai, tahap selanjutnya adalah melakukan pelatihan model *Multilingual BERT* (mBERT). Model ini dipilih karena memiliki kemampuan tinggi dalam memahami konteks bahasa alami (*natural language understanding*) dan telah dilatih sebelumnya (*pretrained*) pada lebih dari 100 bahasa, termasuk Bahasa Indonesia dan Bahasa Malaysia. Pemilihan mBERT dibandingkan model lain seperti LSTM, *fastText*, atau BERT monolingual didasarkan pada kemampuannya menangkap makna kata secara kontekstual serta mempertahankan hubungan sintaksis antar kata, bahkan pada teks pendek yang sering minim informasi. Selain itu, *mBERT* mampu memanfaatkan kesamaan kosakata antar bahasa yang berkerabat, seperti Indonesia dan Malaysia, sekaligus mengenali perbedaan secara presisi.

Proses *fine-tuning* mBERT dilakukan dengan memanfaatkan token khusus [CLS] sebagai representasi keseluruhan kalimat. Seluruh *hidden states* dari mBERT diambil, kemudian hanya vektor [CLS] pada *layer* terakhir yang digunakan sebagai masukan ke lapisan klasifikasi. Pada penelitian ini, semua *layer mBERT* di-*unfreeze* sehingga bobotnya dapat diperbarui selama pelatihan. Strategi ini dipilih agar model dapat menyesuaikan diri secara optimal terhadap karakteristik dataset dari media sosial yang memiliki bahasa tidak baku, singkatan, dan gaya penulisan yang beragam.

Arsitektur akhir model terdiri dari *base model* mBERT sebagai *feature extractor*, diikuti oleh lapisan GlobalAveragePooling1D untuk mereduksi dimensi keluaran tanpa menambah parameter pelatihan, kemudian Dropout(0.4) untuk mengurangi risiko *overfitting* dengan menonaktifkan 40% neuron secara acak saat pelatihan. Lapisan keluaran berupa Dense(2, activation='sigmoid') digunakan untuk menghasilkan dua skor probabilitas terpisah, masing-masing mewakili label Bahasa Indonesia (id) dan Bahasa Malaysia (my). Pendekatan ini memungkinkan model memprediksi satu atau kedua bahasa sekaligus, sehingga mendukung skenario teks campuran.

Model dikompilasi menggunakan *optimizer Adam* dengan *learning rate* sebesar $2e-5$, fungsi kerugian *binary_crossentropy* yang sesuai untuk klasifikasi *multi-label*, serta metrik akurasi untuk memantau kinerja model di setiap *epoch*. Pelatihan dilakukan selama 20 *epoch* dengan *batch size* 16 menggunakan GPU T4 pada platform Google Colab. Strategi *early stopping* diterapkan untuk menghentikan pelatihan lebih awal jika akurasi validasi tidak meningkat dalam beberapa *epoch* berturut-turut, sehingga membantu mencegah *overfitting*.

Selama proses pelatihan, nilai akurasi dan *loss* pada data latih serta validasi dipantau secara *real-time* untuk memastikan model belajar secara stabil. Dengan rancangan ini, mBERT diharapkan mampu mengenali pola linguistik yang membedakan Bahasa Indonesia dan Bahasa Malaysia secara akurat, termasuk pada teks pendek dan teks campuran yang sering ditemukan di media sosial. Model inilah yang menjadi inti dari sistem klasifikasi bahasa yang diusulkan dalam penelitian ini.

4.1.4 Evaluasi Model

Tahap evaluasi model dilakukan untuk menilai sejauh mana model *Multilingual BERT* (mBERT) yang telah dilatih mampu mengklasifikasikan teks ke dalam dua kategori bahasa, yaitu Bahasa Indonesia (ID) dan Bahasa Malaysia (MY), secara akurat. Evaluasi ini penting untuk memastikan bahwa model tidak hanya memiliki performa tinggi pada data latih, tetapi juga dapat melakukan generalisasi yang baik terhadap data yang belum pernah dilihat sebelumnya. Pengujian dilakukan menggunakan *test set* yang telah dipisahkan sejak awal proses pelatihan, sehingga

hasil yang diperoleh benar-benar merefleksikan kemampuan model dalam menghadapi data baru. Berbeda dengan klasifikasi multi-kelas, penelitian ini menggunakan pendekatan klasifikasi *multi-label*, sehingga setiap teks memungkinkan memiliki satu atau kedua label sekaligus, sesuai karakteristik data media sosial.


1. Evaluasi Akurasi dan Loss

Pelatihan model mBERT dilakukan selama 20 *epoch* dengan *batch size* 16, menggunakan GPU T4 pada platform Google Colab. Selama proses pelatihan, nilai akurasi dan *loss* pada data latih maupun data validasi dipantau di setiap *epoch* untuk memastikan proses pembelajaran berjalan stabil dan tidak mengalami penurunan kinerja yang signifikan. Jumlah *epoch* yang relatif sedikit membuat strategi *early stopping* tidak diaktifkan, sehingga pelatihan tetap berlangsung penuh sesuai rencana.

Hasil pengujian menunjukkan bahwa pada *training set*, model mencapai akurasi sebesar 97,25% dengan *loss* sebesar 0,0622, sedangkan pada *test set* akurasi yang diperoleh adalah 95,81% dengan *validation loss* akhir sebesar 0,1329. Perbedaan ini menunjukkan bahwa model tetap mampu melakukan generalisasi dengan baik pada data uji, tanpa mengalami *overfitting* yang signifikan. Selain itu, nilai rata-rata *precision* pada data uji sebesar 0,9798, *recall* sebesar 0,9515, dan *F1-score* sebesar 0,9654. Nilai-nilai ini memperlihatkan adanya keseimbangan yang sangat baik antara ketepatan prediksi (*precision*) dan kemampuan model dalam mengenali data positif secara menyeluruh (*recall*).

Kinerja ini dapat dikatakan sangat tinggi mengingat data yang digunakan berasal dari media sosial yang cenderung bervariasi dan tidak baku, baik dari segi ejaan, penggunaan singkatan, maupun percampuran kosakata antar bahasa. Hal ini membuktikan bahwa mBERT mampu mengenali pola-pola bahasa yang membedakan Bahasa Indonesia dan Bahasa Malaysia secara konsisten, meskipun keduanya memiliki banyak kemiripan kosakata.


2. Confusion Matrix



Gambar 4. 2 *Confusion Matrix* Label Bahasa Indonesia

Gambar 4.2 menampilkan confusion matrix untuk label Bahasa Indonesia (id). Dari total 12.624 data uji, terdapat 9.688 data yang seharusnya berlabel Bahasa Indonesia. Model berhasil mengklasifikasikan 9.389 data sebagai *true positive* (prediksi benar), sedangkan 299 data salah diprediksi sebagai *false negative* (terlewat sebagai Bahasa Indonesia). Pada sisi lain, terdapat 2.936 data yang memang tidak berlabel Bahasa Indonesia, dengan 2.810 data berhasil dikenali sebagai *true negative*, dan 126 data yang salah diklasifikasikan sebagai *false positive*. Nilai *recall* yang tinggi (sekitar 0,97) mengindikasikan bahwa model

jarang melewati teks yang seharusnya masuk kategori Bahasa Indonesia.



Gambar 4.3 *Confusion Matrix* Label Bahasa Malaysia

Gambar 4.3 menunjukkan *confusion matrix* untuk label Bahasa Malaysia (my). Dari total 12.624 data uji, terdapat 5.840 data yang seharusnya berlabel Bahasa Malaysia. Model berhasil mengklasifikasikan 5.386 data sebagai *true positive*, sedangkan 454 data salah diprediksi sebagai *false negative*. Sementara itu, dari 6.784 data yang tidak berlabel Bahasa Malaysia, sebanyak 6.605 data berhasil dikenali sebagai *true negative*, dan 179 data salah diklasifikasikan sebagai *false positive*. Nilai *recall* yang relatif tinggi (sekitar 0,92) menunjukkan bahwa model cukup baik dalam mengenali teks Bahasa Malaysia, meskipun masih ada sebagian kecil teks yang terlewat, terutama pada kalimat yang sangat mirip dengan Bahasa Indonesia.

Berdasarkan hasil pengujian, terlihat bahwa model mampu melakukan klasifikasi dengan cukup baik pada kedua kelas bahasa. Untuk kelas Bahasa Indonesia (ID), sebagian besar teks berhasil diprediksi dengan benar, meskipun

masih terdapat sejumlah teks yang salah dikenali sebagai Bahasa Malaysia. Hal serupa juga terjadi pada kelas Bahasa Malaysia (MY), di mana sebagian besar prediksi sesuai label sebenarnya, namun terdapat kesalahan klasifikasi pada teks-teks yang mengandung kosakata yang mirip dengan Bahasa Indonesia.

Kesalahan prediksi umumnya muncul pada teks yang memiliki bentuk kata serupa atau gaya penulisan yang sulit dibedakan, sehingga menimbulkan ambiguitas, bahkan bagi penutur asli. Meskipun demikian, distribusi pada confusion matrix menunjukkan bahwa jumlah prediksi benar tetap jauh lebih banyak dibandingkan kesalahan, baik pada kelas Bahasa Indonesia maupun Bahasa Malaysia. Hal ini mengindikasikan bahwa model memiliki tingkat akurasi yang seimbang di kedua kelas dan tidak condong memberikan bias pada salah satu bahasa.

Classification Report

Selain *confusion matrix*, digunakan pula *classification report* untuk mengukur performa model dengan tiga metrik utama, yaitu *precision*, *recall*, dan *F1-score*.

Tabel 4. 2 *Classification Report*

Kelas	Deskripsi	Precision	Recall	F1-Score
ID	Bahasa Indonesia	0.99	0.97	0.98
MY	Bahasa Malaysia	0.97	0.92	0.94

Nilai *precision* pada kelas Bahasa Indonesia sebesar 0.99 menunjukkan bahwa hampir semua prediksi sebagai Bahasa Indonesia benar. Nilai *recall* sebesar 0.97 mengindikasikan model mampu mendeteksi sebagian besar teks berlabel Bahasa Indonesia dengan sangat baik. Untuk kelas Bahasa Malaysia, *precision* 0.97 menunjukkan bahwa mayoritas prediksi Bahasa Malaysia benar, sementara *recall* 0.92 mengindikasikan masih ada sebagian kecil teks Bahasa Malaysia yang tidak terdeteksi. Secara keseluruhan, nilai *macro average F1-score* sebesar 0.96 menunjukkan bahwa performa model sangat baik dan relatif seimbang pada kedua label, meskipun masih terdapat sedikit perbedaan dalam kemampuan mendeteksi Bahasa Malaysia dibandingkan Bahasa Indonesia.

Berdasarkan hasil evaluasi, model mBERT yang dilatih pada penelitian ini mampu melakukan klasifikasi bahasa dengan tingkat akurasi yang tinggi, khususnya pada label Bahasa Indonesia, dan tetap memberikan performa yang baik

pada label Bahasa Malaysia. Pendekatan multi-label yang digunakan memungkinkan sistem mengidentifikasi teks campuran yang memuat kedua bahasa, sehingga cocok diterapkan untuk analisis teks di media sosial yang memiliki karakteristik dinamis dan beragam.

4.2 Hasil Implementasi

Setelah seluruh tahapan pemodelan selesai dilakukan, langkah selanjutnya adalah tahap implementasi sistem ke dalam platform berbasis web. Dalam penelitian ini, implementasi dilakukan menggunakan *Streamlit*, sebuah *framework* Python yang memungkinkan pembuatan antarmuka pengguna secara interaktif dan cepat. Pengembangan antarmuka ini mengikuti rancangan yang telah ditetapkan pada Bab III, sehingga setiap komponen yang ditampilkan selaras dengan desain sistem yang direncanakan.

4.2.1 Halaman Awal Sistem Klasifikasi

Pada tahap implementasi antarmuka, halaman awal sistem dirancang sederhana namun informatif agar pengguna dapat langsung memahami fungsi utama aplikasi. Tampilan ini menampilkan judul besar "Klasifikasi Bahasa Indonesia vs Bahasa Malaysia" di bagian atas, diikuti dengan keterangan model yang digunakan, yaitu *Multilingual BERT (mBERT)*.

Di bawah keterangan model terdapat kolom input teks berukuran besar yang memungkinkan pengguna memasukkan kalimat atau paragraf singkat yang ingin dianalisis. Pengguna dapat mengetik langsung ke dalam kolom ini atau menyalin teks dari sumber lain. Tepat di bawah kolom input, terdapat tombol "Klasifikasikan" yang berfungsi untuk memulai proses klasifikasi.




Gambar 4. 4 Halaman Utama

Desain halaman awal ini dibuat bersih, terpusat, dan responsif sehingga dapat diakses baik dari perangkat desktop maupun mobile. Tidak ada elemen yang mengganggu fokus, sehingga perhatian pengguna tertuju langsung pada proses memasukkan teks dan melakukan prediksi. Pendekatan minimalis ini bertujuan untuk mempermudah interaksi pengguna dengan sistem, sekaligus mempercepat proses penggunaan tanpa memerlukan banyak navigasi.

4.2.2 Halaman Hasil Sistem Klasifikasi

Pada tahap ini, sistem menampilkan hasil klasifikasi berdasarkan konfigurasi yang telah ditentukan oleh pengguna. Gambar 4.4 memperlihatkan hasil keluaran dari sistem klasifikasi yang telah diproses sesuai dengan input yang diberikan oleh pengguna.



Gambar 4. 5 Halaman Hasil Klasifikasi

Setelah pengguna menekan tombol "Klasifikasikan" pada halaman utama, sistem akan memproses teks yang dimasukkan melalui model *Multilingual BERT (mBERT)* yang telah dilatih sebelumnya. Proses ini berlangsung secara real-time, sehingga hasil klasifikasi dapat langsung dilihat tanpa perlu memuat ulang halaman. Bagian hasil klasifikasi ditampilkan pada halaman yang sama, tepat di bawah tombol eksekusi. Informasi yang disajikan meliputi:

1. **Prediksi Kelas Bahasa** – Sistem akan menunjukkan label bahasa yang diprediksi, yaitu apakah teks tersebut termasuk Bahasa Indonesia (ID), Bahasa Malaysia (MY) atau campuran.
2. **Probabilitas Prediksi** – Hasil prediksi disertai dengan nilai probabilitas dalam bentuk persentase, yang menggambarkan tingkat keyakinan model terhadap keputusan tersebut. Probabilitas ini dihitung berdasarkan keluaran *sigmoid* dari model, sehingga total persentase untuk kedua kelas tidak selalu berjumlah 100%.

Desain tampilan hasil dibuat sederhana dan fokus pada informasi utama, dengan judul prediksi ditulis tebal agar mudah terbaca. Nilai probabilitas untuk kedua kelas bahasa ditampilkan secara terpisah agar pengguna dapat membandingkan tingkat keyakinan model pada masing-masing kemungkinan bahasa.

Sebagai contoh, ketika pengguna memasukkan teks slang media sosial seperti "Harum nye ni", sistem memprediksi bahwa teks tersebut termasuk Bahasa

Malaysia dengan probabilitas 93,62%, sedangkan probabilitas untuk Bahasa Indonesia hanya 5,96%. Hal ini menunjukkan bahwa model memiliki tingkat keyakinan yang sangat tinggi terhadap prediksi tersebut.

Contoh lain, jika dimasukkan teks "sy nak makan lg la", sistem juga memberikan hasil prediksi Bahasa Malaysia dengan probabilitas yang sangat tinggi, yaitu 99,98%, dan Bahasa Indonesia sebesar 0,02%. Hasil ini sejalan dengan analisis linguistik bahwa kosakata seperti "nak" dan partikel "la" lebih sering digunakan dalam Bahasa Malaysia, khususnya dalam percakapan santai atau informal di media sosial. Dengan penyajian hasil yang ringkas namun informatif ini, pengguna dapat langsung memahami bahasa yang terdeteksi oleh sistem tanpa harus membaca penjelasan teknis yang kompleks.

4.2.3 Ringkasan Pengujian Implementasi

Berdasarkan serangkaian pengujian yang dilakukan menggunakan aplikasi berbasis Streamlit, sistem menunjukkan kemampuan klasifikasi yang cukup cepat dan akurat. Rata-rata waktu respon untuk memproses satu input teks kurang dari satu detik, sehingga pengguna dapat langsung memperoleh hasil prediksi secara *real-time*. Kecepatan ini didukung oleh proses *inference* pada model Multilingual BERT (*mBERT*) yang telah melalui tahap *fine-tuning*.

Dari hasil uji coba, tingkat akurasi implementasi sistem konsisten dengan evaluasi pada *test set*, yakni berada pada kisaran 95–96%. Hal ini menegaskan bahwa model tidak hanya bekerja baik pada data pelatihan, tetapi juga mampu mempertahankan kinerjanya saat digunakan di lingkungan aplikasi nyata. Untuk memastikan sistem dapat mengenali variasi penulisan yang umum pada media sosial, pengujian dilakukan menggunakan teks dengan ejaan tidak baku, singkatan, maupun campuran Bahasa Indonesia dan Bahasa Malaysia. Beberapa contoh hasil klasifikasi ditunjukkan pada Tabel 4.3 berikut.

Tabel 4. 3 Hasil Klasifikasi Contoh Teks Uji

No Input Teks	Prediksi Bahasa	Probabilitas (%)
1 “Harum nye ni”	Bahasa Malaysia	93.62
2 “bauun nye”	Bahasa Malaysia	98.43
3 “saya nak makan”	Campuran	ID: 63.86 / MY: 74.40
4 “saya lagi makan”	Campuran	ID: 88.41 / MY: 68.59
5 “jom la makan di rumah gue”	Campuran	ID: 87.51 / MY: 51.54
6 “saya makan bakso di dekat warung rumah”	Bahasa Indonesia	99.59

Dari hasil di atas terlihat bahwa sistem mampu mengenali bahasa dengan cukup baik, bahkan ketika teks mengandung singkatan atau gaya bahasa informal. Misalnya, pada teks “*bauun nye*”, sistem secara tepat mengklasifikasikannya sebagai Bahasa Malaysia dengan tingkat keyakinan 98,43%. Sementara pada teks “*saya lagi makan*” yang berpotensi ambigu karena kosakata umum digunakan di kedua bahasa, sistem memberikan prediksi campuran dengan probabilitas cukup tinggi pada keduanya.

Pengujian ini memperlihatkan bahwa aplikasi tidak hanya efektif untuk teks formal, tetapi juga cukup andal dalam menangani teks tidak baku yang sering ditemui di media sosial. Dengan demikian, sistem klasifikasi berbasis *mBERT* ini berpotensi digunakan secara praktis, baik oleh peneliti linguistik, analis media sosial, maupun masyarakat umum yang membutuhkan deteksi bahasa secara cepat dan akurat.

BAB V

KESIMPULAN

5.1 Kesimpulan

Berdasarkan Berdasarkan hasil penelitian dan implementasi sistem klasifikasi bahasa menggunakan metode Multilingual BERT (mBERT), dapat disimpulkan bahwa model mampu membedakan teks berbahasa Indonesia dan Malaysia secara cukup efektif, baik pada teks formal maupun informal yang bersumber dari media sosial. Tantangan utama berupa data yang noisy, variasi penulisan, singkatan, serta campuran kosakata berhasil diatasi melalui tahap preprocessing yang mencakup pembersihan karakter khusus, *case folding*, normalisasi kata tidak baku, penghapusan spasi ganda, tokenisasi, dan *padding/truncating*. Hasil evaluasi menunjukkan bahwa model menghasilkan akurasi sekitar 95–96% dengan nilai *F1-score* rata-rata 0.96, yang menandakan performa model cukup stabil di kedua kelas bahasa meskipun masih terdapat kesalahan pada teks yang memiliki kosakata mirip di kedua bahasa.

Implementasi sistem berbasis web menggunakan *Streamlit* berhasil merealisasikan model menjadi aplikasi yang praktis dan responsif. Sistem dapat memberikan hasil prediksi dalam waktu kurang dari satu detik dengan menampilkan label bahasa serta nilai probabilitasnya, sehingga memudahkan pengguna memahami tingkat keyakinan model. Dengan demikian, penelitian ini membuktikan bahwa pendekatan mBERT yang dipadukan dengan *preprocessing* yang tepat mampu menghasilkan sistem klasifikasi bahasa yang aplikatif, dapat diandalkan pada data nyata di media sosial, serta berpotensi dikembangkan lebih lanjut untuk analisis konten, moderasi teks, maupun integrasi ke dalam chatbot multibahasa.

5.2 Saran

Berdasarkan hasil penelitian dan pengujian sistem, beberapa saran untuk pengembangan selanjutnya antara lain:

1. Perluasan dan Variasi Dataset

Disarankan untuk menambah data dari platform media sosial lain selain

Twitter, seperti Facebook atau Instagram, agar model lebih mampu menghadapi variasi bahasa sehari-hari, termasuk penggunaan slang, singkatan, dan campuran bahasa (code-switching).

2. Penanganan Kata Ambigu dan Kosakata Serumpun

Perlu strategi khusus, misalnya *contextual disambiguation* atau pelatihan tambahan (*continual learning*), agar model dapat lebih akurat dalam membedakan kata yang sama tetapi memiliki makna berbeda di Indonesia dan Malaysia.

3. Penambahan Kategori Bahasa Lain (Opsional)

Untuk mencegah kesalahan klasifikasi pada bahasa asing (misalnya Inggris, Jerman, atau Tagalog) yang sering muncul di media sosial, sistem dapat dikembangkan dengan menambahkan kategori "Bahasa Lain" sehingga tidak selalu dipaksa masuk ke Bahasa Indonesia atau Malaysia.

4. Optimasi Model untuk Produksi

Ukuran model dapat diperkecil dengan teknik *model distillation* agar lebih efisien dijalankan pada perangkat bergerak (*mobile*) maupun aplikasi berbasis web, sehingga memudahkan pengguna umum.

Dengan pengembangan tersebut, sistem klasifikasi berbasis mBERT diharapkan lebih akurat, kontekstual, dan bermanfaat untuk mengurangi salah paham komunikasi digital antara masyarakat Indonesia dan Malaysia.

DAFTAR PUSTAKA

- Abdiansah, A., & Rizqie, M. Q. (t.t.). *Automatic Language Identification for Indonesian-Malaysian Language Using Machine Learning*.
- Alsmadi, I., & Gan, K. H. (2019). Review of short-text classification. *International Journal of Web Information Systems*, 15(2), 155–182. <https://doi.org/10.1108/IJWIS-12-2017-0083>
- Ansari, M. Z., Ahmad, T., & Fatima, A. (2020). *Feature Selection on Noisy Twitter Short Text Messages for Language Identification*.
- Badan Pengembangan dan Pembinaan Bahasa. (2016). *Kamus Besar Bahasa Indonesia (Edisi V)*. Kementerian Pendidikan dan Kebudayaan. <https://kbbi.kemdikbud.go.id>
- Conneau, A., Khandelwal, K., Goyal, N., Chaudhary, V., Wenzek, G., Guzmán, F., Grave, E., Ott, M., Zettlemoyer, L., & Stoyanov, V. (t.t.). *Unsupervised Cross-lingual Representation Learning at Scale*. <https://github.com/facebookresearch/cc>
- Conneau, A., Khandelwal, K., Goyal, N., Chaudhary, V., Wenzek, G., Guzmán, F., Grave, E., Ott, M., Zettlemoyer, L., & Stoyanov, V. (2019). *Unsupervised Cross-lingual Representation Learning at Scale*. <http://arxiv.org/abs/1911.02116>
- Devlin, J., Chang, M.-W., Lee, K., Google, K. T., & Language, A. I. (t.t.). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. <https://github.com/tensorflow/tensor2tensor>
- Dewan Bahasa dan Pustaka. (2005). *Kamus Dewan (Edisi Keempat)*. Dewan Bahasa dan Pustaka. <https://prpm.dbp.gov.my/>
- Guo, X., Adnan, H. M., & Abidin, M. Z. Z. (2024). Detecting Offensive Language on Malay Social Media: A Zero-Shot, Cross-Language Transfer Approach Using Dual-Branch mBERT. *Applied Sciences (Switzerland)*, 14(13). <https://doi.org/10.3390/app14135777>

- Haque, S., Eberhart, Z., Bansal, A., & McMillan, C. (2022). Semantic Similarity Metrics for Evaluating Source Code Summarization. *IEEE International Conference on Program Comprehension, 2022-March*, 36–47.
<https://doi.org/10.1145/nnnnnnnn.nnnnnnnn>
- Jauhiainen, T., Lindén, K., & Jauhiainen, H. (2019). Language model adaptation for language and dialect identification of text. Dalam *Natural Language Engineering* (Vol. 25, Nomor 5, hlm. 561–583). Cambridge University Press.
<https://doi.org/10.1017/S135132491900038X>
- Kajian, S., Upaya, A., Kesalahpahaman, M., Budaya, P., Bangsa, A., Di, S., Tenggara, A., Perbedaan, D., Antara, B., Serumpun, B., Asia, D., Promadi, T., Tarbiyah, F., Keguruan, D., & Riau, K. (2012). PERBEDAAN SEMANTIK ANTARA BAHASA INDONESIA DAN BAHASA MALAYSIA: PERBEDAAN SEMANTIK ANTARA BAHASA INDONESIA DAN BAHASA MALAYSIA: Satu Kajian Awal Upaya Mengelak Kesalahpahaman. Dalam *Jurnal Sosial Budaya* (Vol. 9, Nomor 2).
- Kolluri, J., Razia, S., & Ranjan Nayak, S. (t.t.). *Text classification using Machine Learning and Deep Learning Models*. <https://ssrn.com/abstract=3618895>
- Li, H., & Li, Z. (2022). Text Classification Based on Machine Learning and Natural Language Processing Algorithms. *Wireless Communications and Mobile Computing, 2022*. <https://doi.org/10.1155/2022/3915491>
- Maxwell-Smith, Z., Kohler, M., & Suominen, H. (t.t.). *Scoping natural language processing in Indonesian and Malay for education applications*.
- Pires, T., Schlinger, E., & Garrette, D. (2019). *How multilingual is Multilingual BERT?* <https://github.com/google-research/bert>
- Putra, I. F., & Purwarianti, A. (2020, September 8). Improving Indonesian Text Classification Using Multilingual Language Model. *2020 7th International Conference on Advanced Informatics: Concepts, Theory and Applications, ICAICTA 2020*. <https://doi.org/10.1109/ICAICTA49861.2020.9429038>

- Review, W. P. (2025). *Twitter Users by Country – Indonesia (27.1 million users in 2024)*.
- Singh, G., Sharma, S., Kumar, V., Kaur, M., Baz, M., & Masud, M. (2021). Spoken Language Identification Using Deep Learning. *Computational Intelligence and Neuroscience*, 2021. <https://doi.org/10.1155/2021/5123671>
- Sirulhaq, A., & Kurniawan, M. A. (2024). Regional Identity and Lingua Franca in the ASEAN Region: A Comparative Study of Indonesian and Malay. *Journal of ASEAN Studies*, 12(2), 383–412. <https://doi.org/10.21512/jas.v12i2.9582>
- Widada, C. K. (2018). MENGAMBIL MANFAAT MEDIA SOSIAL DALAM PENGEMBANGAN LAYANAN. *Journal of Documentation and Information Science*, 2(1), 23–30. <https://doi.org/10.33505/jodis.v2i1.130>
- Wu, S., & Dredze, M. (2020). *Are All Languages Created Equal in Multilingual BERT?*
- Zuo, X., Yang, X., Dou, Z., & Wen, J. R. (2019). RUCIR at TREC 2019: Conversational Assistance Track. *28th Text REtrieval Conference, TREC 2019 - Proceedings*. <https://doi.org/10.1145/1122445.1122456>

LAMPIRAN

